COLE.VN

connecting knowledge

COLE.VN
Connecting knowledge

Chủ đề:

Mạng nơ-ron (neural network)

Mục đích buổi học

- Lý thuyết xây dựng mạng Nơ ron nhân tạo
- Thuật toán học cho mạng Nơron nhân tạo: Gradient Descend

Lịch sử

- 1958: Nhà tâm lý học Frank Rosenblatt tạo ra mạng nơron (neural) nhân tạo
  - Đặt tên là Perceptron
  - Mục đích mô hình hoá quá trình nhận thức của con người
  - Trong một thời gian dài, Neural Nets chỉ là một khái niệm hơn là một công cụ thực tế.
- 1986: Bài báo về thuật toán backpropagation bởi Rumelhar et al.
  - Cách huấn luyện mạng nơron
  - Neural network đã tạo được những bước tiến nhỏ nhưng chắc chắn nhờ sự hỗ trợ của sức mạnh tính toán
- 2012: mạng nơ ron tích chập (CNN) AlexNet đã chiến thắng trong ImageNet 2012
  - Deeplearning trở thành tâm điểm chú ý đến ngày nay

Lịch sử

Sự phát triển neural net nhờ sự phát triển của sức mạnh tính toán

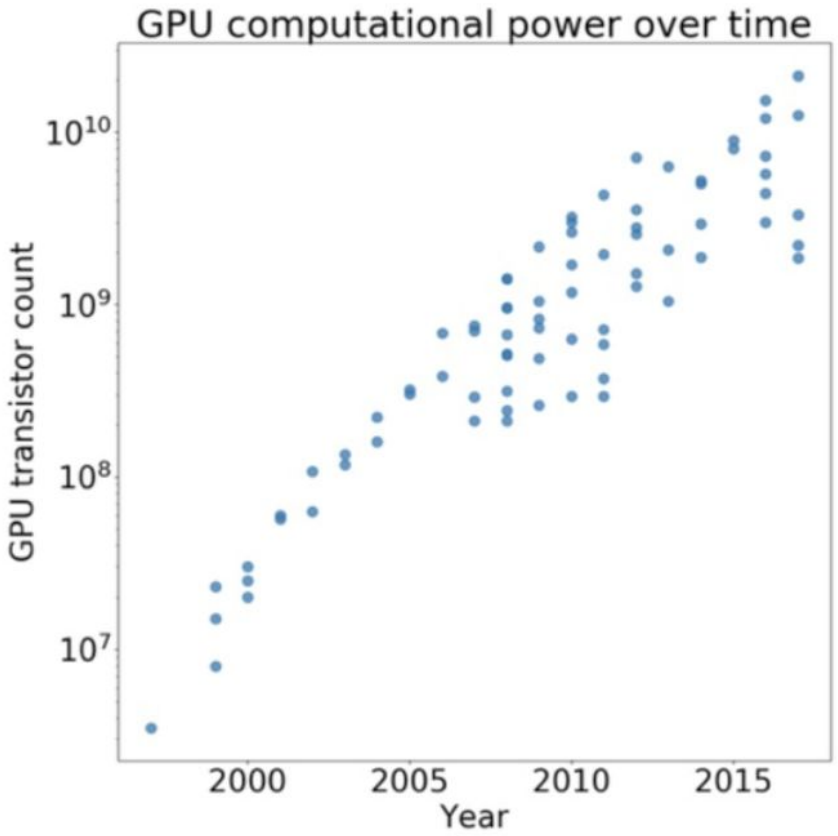

Mạng neural trong não người

- Neural: thành phần chính của mô thần kinh ở hầu hết các loài động vật
  - Mạng neural trong não người
  - Tiếp nhận tín hiệu đầu vào (input) qua các dendrites
  - Các tín hiệu sẽ được neural quyết định xem có được đi qua không tại nucleus
    - Nếu được qua: các tín hiệu này sẽ đến axon và truyền qua các dendrites của các neural khác
  - Một axon xuất các tín hiệu đầu ra (output)

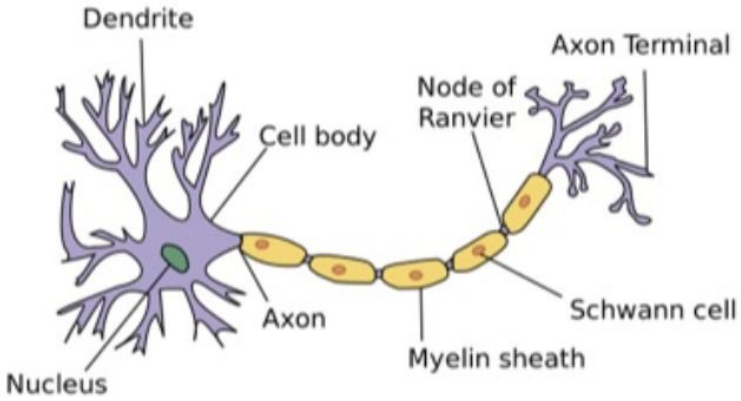

Human neuron

Mạng nơ-ron nhân tạo: Giới thiệu

- Mạng nơ-ron nhân tạo (Artificial neural network – ANN)
  - Mô phỏng các hệ thống nơ-ron sinh học (các bộ não con người)
  - ANN là một cấu trúc (structure/network) được tạo nên bởi một số lượng các nơ-ron (artificial neurons) liên kết với nhau
- Mỗi nơ-ron
  - Có một đặc tính vào/ra
  - Thực hiện một tính toán cục bộ (một hàm cục bộ)
- Giá trị đầu ra của một nơ-ron được xác định bởi
  - Đặc tính vào/ra của nó
  - Các liên kết của nó với các nơ-ron khác
  - (Có thể) các đầu vào bổ sung

Mạng nơ-ron nhân tạo: Giới thiệu

- ANN có thể được xem như một cấu trúc xử lý thông tin một cách phân tán và song song ở mức cao
- ANN có khả năng học (learn), nhớ lại (recall), và khái quát hóa (generalize) từ các dữ liệu học
- Khả năng của một ANN phụ thuộc vào
  - Kiến trúc (topology) của mạng nơ-ron
  - Đặc tính đầu vào/ra của mỗi nơ-ron
  - Thuật toán học (huấn luyện)
  - Dữ liệu học

Cấu trúc và hoạt động của một nơ-ron

- **Các tín hiệu đầu vào (input signals)** của nơ-ron (x_i, i=1..m)
- Trọng số **điều chỉnh (bias)** w_0 (với x_0 = 1)
- **Đầu vào tổng thể (Net input)** là một hàm tích hợp của các tín hiệu đầu vào – `Net(w,x)`
- **Hàm tác động/truyền (Activation/transfer function)** tính giá trị đầu ra của nơ-ron – `f(Net(w,x))`
- **Giá trị đầu ra (Output)** của nơ-ron: `Out=f(Net(w,x))`

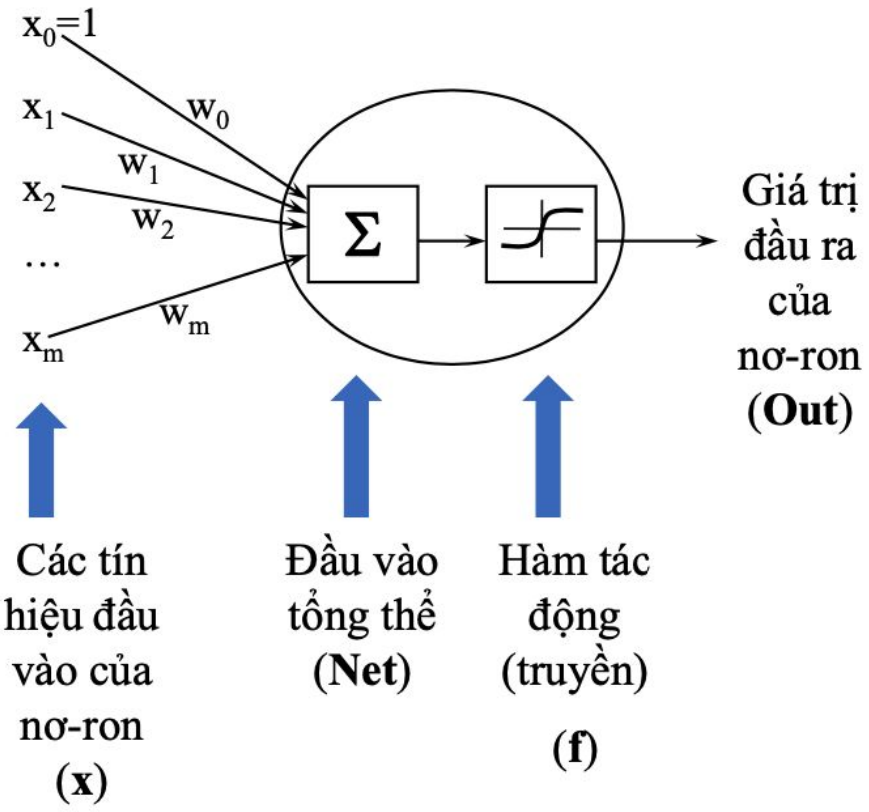

Đầu vào nơ-ron

- Thông tin đầu vào được tổng hợp lại và đưa vào **đầu vào tổng thể**
- Mỗi nút bổ sung thêm thông tin và đóng góp thêm một phần vào **output** của nơ-ron
- Càng có nhiều nút (thông tin), chúng ta càng có thể nắm bắt được nhiều tác động hơn
- Mỗi nút đi kèm một trọng số điều chỉnh w_i thể hiện độ quan trọng của **thông tin đầu vào** đó đối với **thông tin đầu ra**

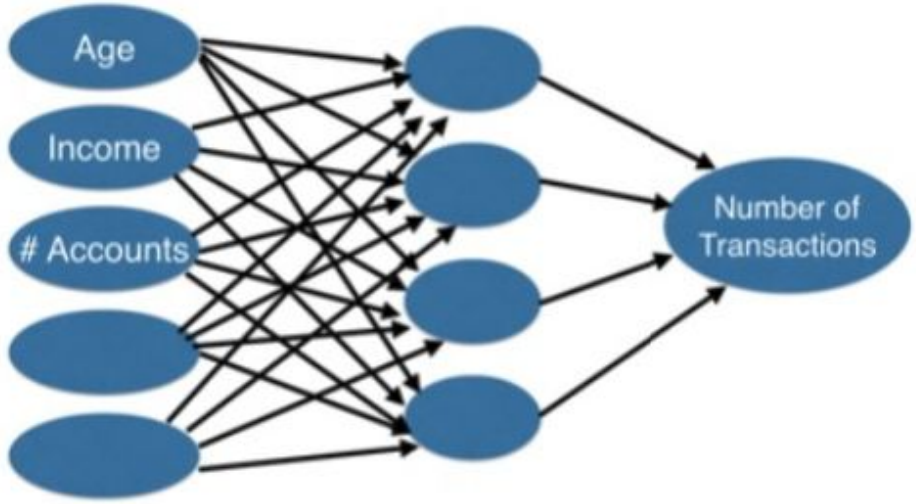

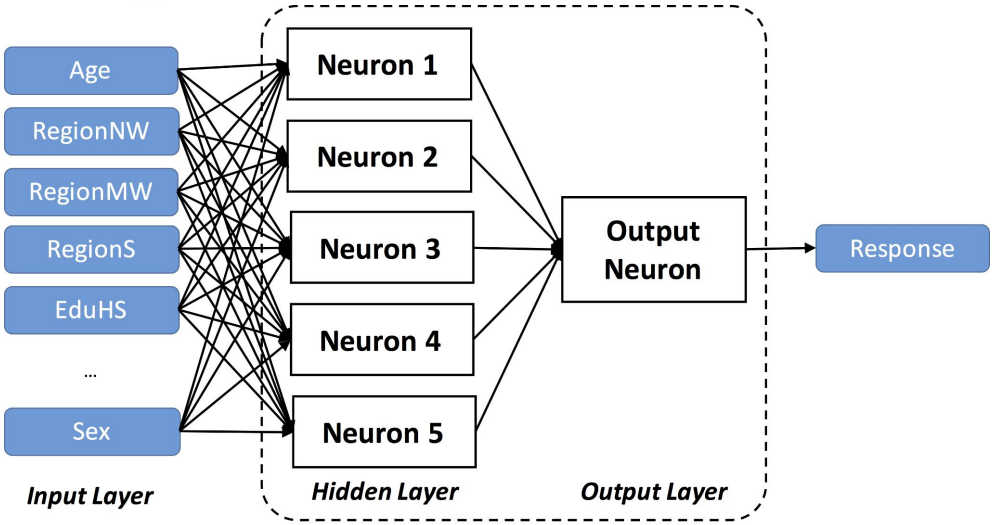

Đầu vào tổng thể

- Đầu vào tổng thể (**net input**) thường được tính toán bởi một hàm tuyến tính

$$Net = w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_m x_m = w_0 .1 + \sum_{i=1}^{m} w_i x_i = \sum_{i=0}^{m} w_i x_i$$

- Ý nghĩa của trọng số điều chỉnh (bias) w_0

→ Họ các hàm **Net=w_1x_1** không thể phân tách được các ví dụ thành 2 lớp (two classes)

→ Nhưng: họ các hàm **Net=w_1x_1+w_0** có thể!

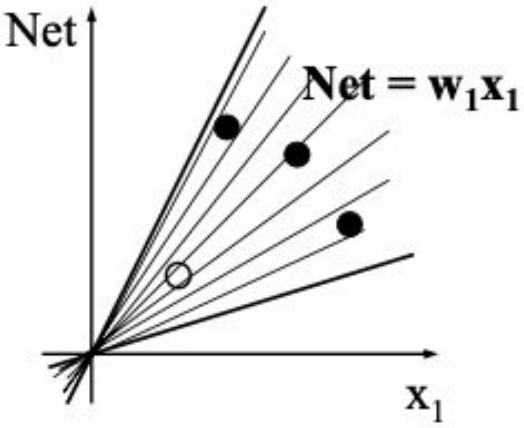

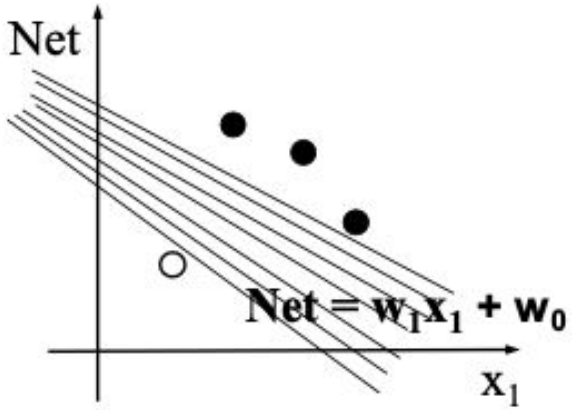

Hàm tác động trong nơ-ron

- Hàm tác động mô phỏng tỷ lệ truyền xung qua axon của một neuron thần kinh. Trong một mạng nơ-ron nhân tạo, hàm kích hoạt đóng vai trò là thành phần phi tuyến tại output của các nơ-ron.

Tại sao lại cần các hàm kích hoạt phi tuyến?

- Câu trả lời là nếu không có các hàm kích hoạt phi tuyến, thì mạng nơ-ron của chúng ta dù có nhiều lớp vẫn sẽ có hiệu quả như một lớp tuyến tính mà thôi.

Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

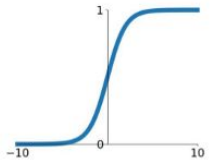

Leaky ReLU

$$\max(0.1x, x)$$

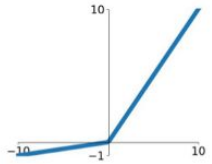

tanh

$$\tanh(x)$$

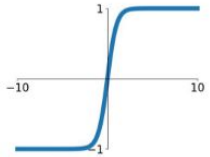

Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ReLU

$$\max(0, x)$$

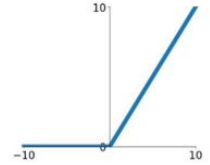

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

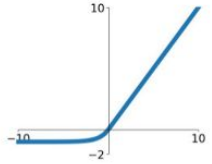

Hàm tác động: Giới hạn cứng

- Còn được gọi là hàm ngưỡng (threshold function)
- Giá trị đầu ra lấy một trong 2 giá trị
- θ là giá trị ngưỡng
- **Nhược điểm**: không liên tục, không có đạo hàm

$$Out(Net) = HL(Net, q) = \begin{cases} 1, & \text{if } Net \geq q \\ 0, & \text{otherwise} \end{cases}$$

$$Out(Net) = HL2(Net, q) = sign(Net, q)$$

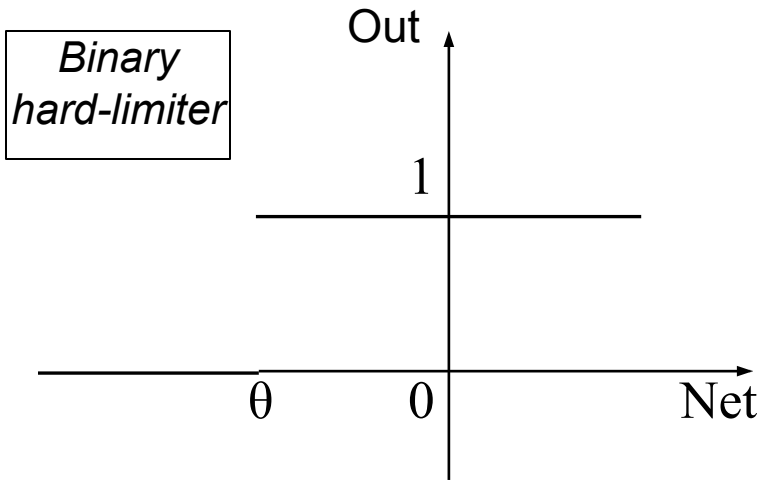

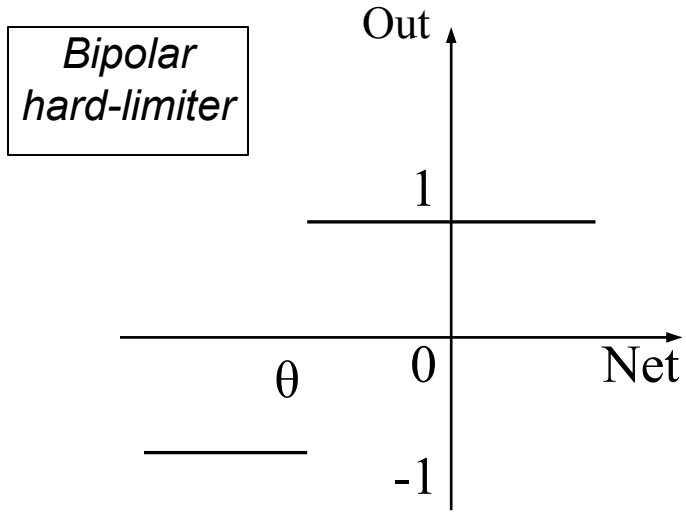

Hàm tác động: Logic ngưỡng

$$Out(Net) = tl(Net, \alpha, \theta) = \begin{cases} 0, & \text{if } Net < -\theta \\ \alpha(Net + \theta), & \text{if } -\theta \le Net \le \frac{1}{\alpha} - \theta \\ 1, & \text{if } Net > \frac{1}{\alpha} - \theta \end{cases}$$

$$= \max(0, \min(1, \alpha(Net + \theta)))$$

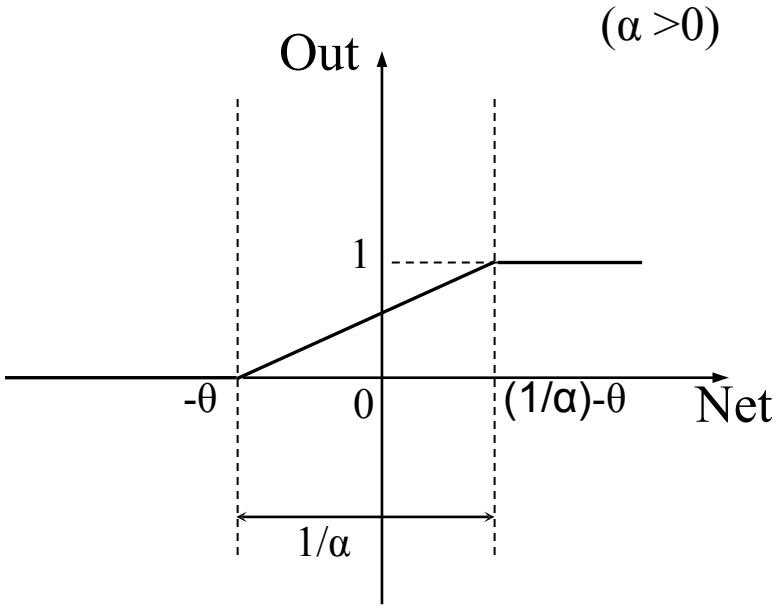

- Còn được gọi là hàm tuyến tính bão hòa (saturating linear function)
- Kết hợp của 2 hàm tác động: tuyến tính và giới hạn chặt
- α xác định độ dốc của khoảng tuyến tính
- **Nhược điểm**: Liên tục, nhưng không có đạo hàm

Hàm tác động: Sigmoid

$$Out(Net) = sf(Net, \alpha, \theta) = \frac{1}{1 + e^{-\alpha(Net+\theta)}}$$

- Được dùng phổ biến
- Tham số α xác định độ dốc
- Giá trị đầu ra trong khoảng (0,1)
- **Ưu điểm**
  - Liên tục, và đạo hàm liên tục
  - Đạo hàm của một hàm sigmoid được biểu diễn bằng một hàm của chính nó

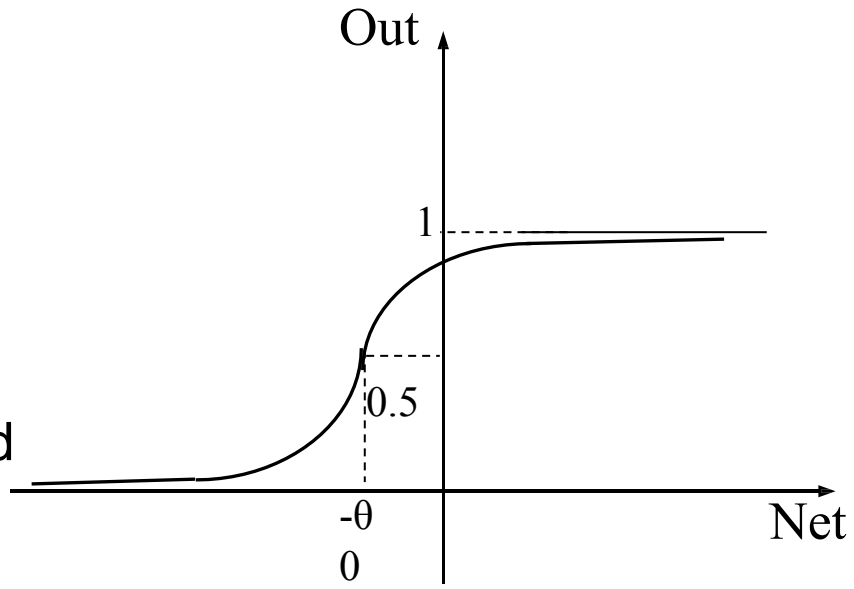

Hàm tác động: Hyperbolic tangent

$$Out(Net) = \tanh(Net, \alpha, \theta) = \frac{1 - e^{-\alpha(Net+\theta)}}{1 + e^{-\alpha(Net+\theta)}} = \frac{2}{1 + e^{-\alpha(Net+\theta)}} - 1$$

- Cũng hay được sử dụng
- Tham số α xác định độ dốc
- Giá trị đầu ra trong khoảng (-1,1)
- **Ưu điểm**
  - Liên tục, và đạo hàm liên tục
  - Đạo hàm của một hàm tanh có thể được biểu diễn bằng một hàm của chính nó

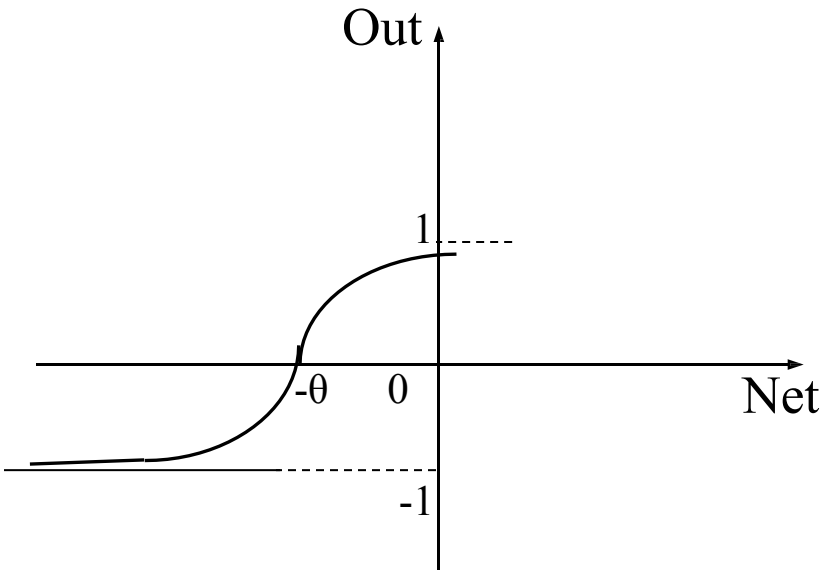

Hàm tác động: rectified linear unit (ReLU)

$$Out(net) = \max(0, net)$$

- Được sử dụng nhiều nhất hiện nay
- Giá trị đầu ra luôn không âm
- **Ưu điểm**
  - Liên tục
  - Không có đạo hàm tại điểm 0 duy nhất.
  - Dễ tính toán

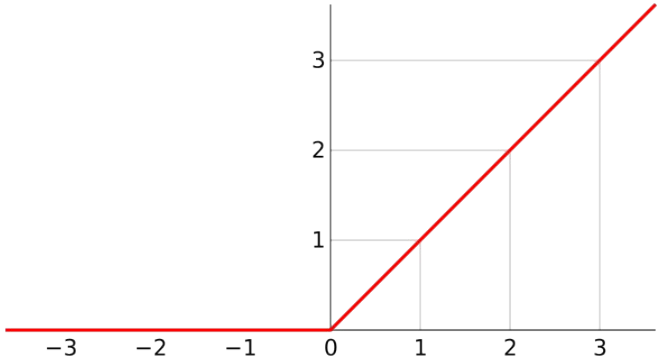

ANN: Kiến trúc mạng (1)

- Kiến trúc của một ANN được xác định bởi:
  - Số lượng các tín hiệu đầu vào và đầu ra
  - Số lượng các tầng
  - Số lượng các nơ-ron trong mỗi tầng
  - Số lượng các liên kết đối với mỗi nơ-ron
  - Cách thức các nơ-ron (trong một tầng, hoặc giữa các tầng) liên kết với nhau
- Một ANN phải có
  - Một tầng đầu vào (input layer)
  - Một tầng đầu ra (output layer)
  - Không, một, hoặc nhiều tầng ẩn (hidden layer(s))

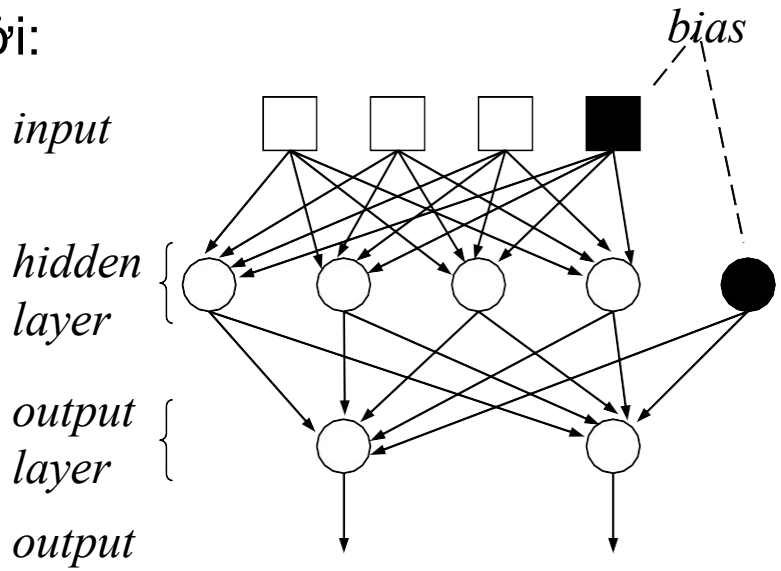

Ví dụ: Một ANN với một tầng ẩn

- Đầu vào: 3 tín hiệu
- Đầu ra: 2 giá trị
- Tổng cộng, có 6 neurons
  - 4 ở tầng ẩn
  - 2 ở tầng đầu ra

ANN: Kiến trúc mạng (2)

- Một tầng (layer) chứa một nhóm các nơ-ron
- Tầng ẩn (hidden layer) là một tầng nằm ở giữa tầng đầu vào (input layer) và tầng đầu ra (output layer)
- Các nút ở tầng ẩn (hidden nodes) không tương tác trực tiếp với môi trường bên ngoài (của mạng nơ-ron)
- Một ANN được gọi là ***liên kết đầy đủ (fully connected)*** nếu mọi đầu ra từ một tầng liên kết với mọi nơ-ron của tầng kế tiếp

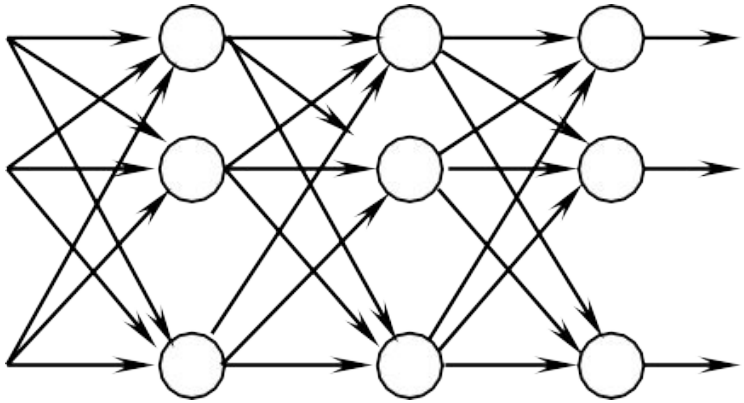

ANN: Kiến trúc mạng (3)

- Một ANN được gọi là ***mạng lan truyền tiến (feed- forward network)*** nếu không có bất kỳ đầu ra của một nút là đầu vào của một nút khác thuộc cùng tầng (hoặc thuộc một tầng phía trước)
- Khi các đầu ra của một nút liên kết ngược lại làm các đầu vào của một nút thuộc cùng tầng (hoặc thuộc một tầng phía trước), thì đó là một ***mạng phản hồi (feedback network)***
  - Nếu phản hồi là liên kết đầu vào đối với các nút thuộc cùng tầng, thì đó là ***phản hồi bên (lateral feedback)***
- Các mạng phản hồi có các vòng lặp kín (closed loops) được gọi là **các mạng hồi quy (*recurrent networks)***

ANN: Kiến trúc mạng (4)

Mạng lan truyền tiến một tầng

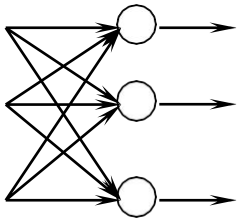

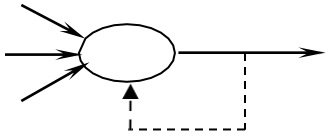

Một nơ-ron với phản hồi đến chính nó

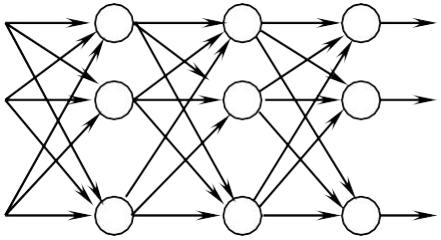

Mạng lan truyền tiến nhiều tầng

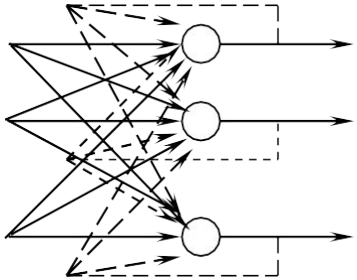

Mạng hồi quy một tầng

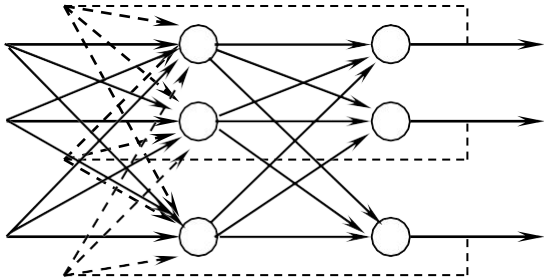

Mạng hồi quy nhiều tầng

ANN: Cách huấn luyện

- 2 kiểu học trong các mạng nơ-ron nhân tạo
  - *Học tham số (Parameter learning)*

    → Mục tiêu là thay đổi thích nghi các trọng số (weights) của các liên kết trong mạng nơ-ron
  - *Học cấu trúc (Structure learning)*

    → Mục tiêu là thay đổi thích nghi cấu trúc mạng, bao gồm số lượng các nơ-ron và các kiểu liên kết giữa chúng

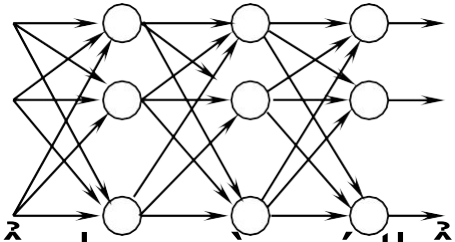

Or

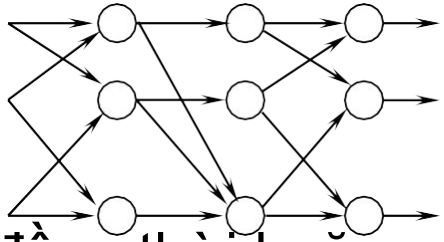

- 2 kiểu học này có thể được thực hiện đồng thời hoặc riêng rẽ
- Trong bài học này, chúng ta sẽ chỉ xét việc học tham số

ANN: ý tưởng

- Huấn luyện một mạng nơron (khi cố định kiến trúc) chính là việc học các trọng số **w** của mạng từ tập học **D**.
- Đưa việc học về bài toán cực tiểu hoá một hàm lỗi thực nghiệm:

$$L(w) = \frac{1}{|D|}\sum_{x \in D} loss(d_x, out(x))$$

  - Trong đó out(x) là đầu ra của mạng, với đầu vào x có nhãn tương ứng là d_x; loss là một hàm đo lỗi phán đoán.
- Nhiều phương pháp lặp dựa trên Gradient:
  - Backpropagation
  - SGD
  - Adam
  - AdaGrad

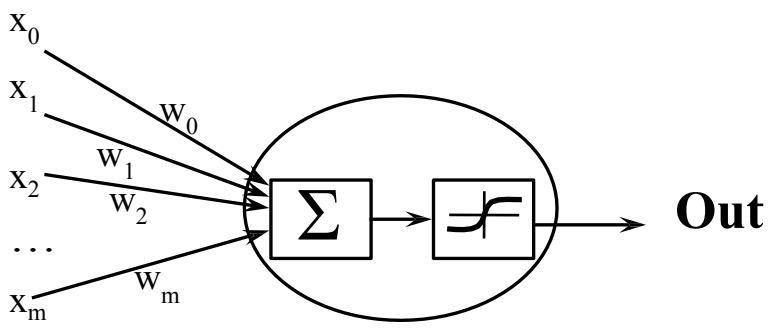

Perceptron

- Một perceptron là một kiểu đơn giản nhất của ANNs (chỉ gồm duy nhất một nơ-ron)
- Sử dụng hàm tác động giới hạn chặt

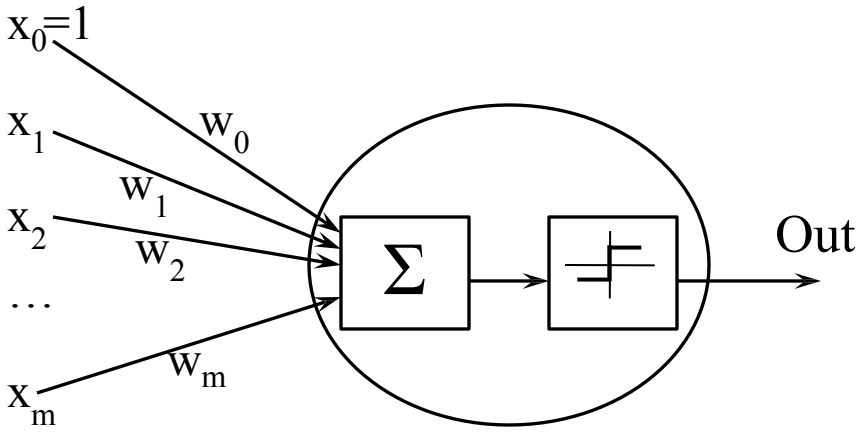

$$Out = sign\big(Net(w,x)\big) = sign\left(\sum_{j=0}^{m} w_j x_j\right)$$

- Đối với một ví dụ ***x***, giá trị đầu ra của perceptron là
  - 1, nếu Net(**w**,**x**) > 0
  - -1, nếu ngược lại

Perceptron: Minh họa

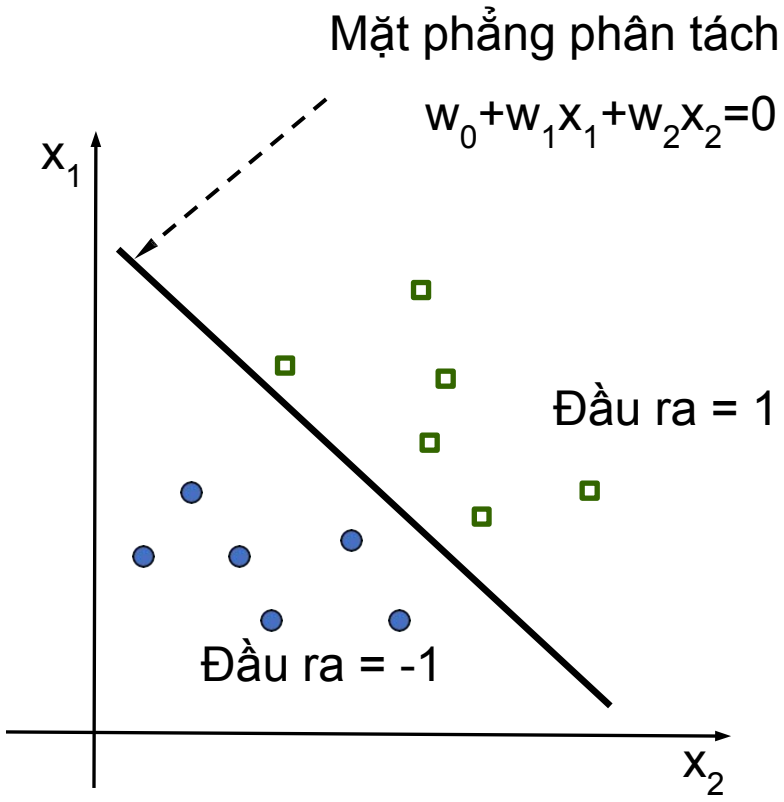

Perceptron: Giải thuật học

- Với một tập các ví dụ học D= {(**x**,d)}
  - ***x*** là vectơ đầu vào
  - *d* là giá trị đầu ra mong muốn (-1 hoặc 1)
- Quá trình học của perceptron nhằm xác định một vectơ trọng số cho phép perceptron sinh ra giá trị đầu ra chính xác (-1 hoặc 1) cho mỗi ví dụ học
- Với một ví dụ học ***x*** được perceptron phân lớp chính xác, thì vectơ trọng số ***w*** không thay đổi
- Nếu d=1 nhưng perceptron lại sinh ra -1 (Out=-1), thì ***w*** cần được thay đổi sao cho giá trị Net(**w**,**x**) tăng lên
- Nếu d=-1 nhưng perceptron lại sinh ra 1 (Out=1), thì ***w*** cần được thay đổi sao cho giá trị Net(**w**,**x**) giảm đi

Perceptron: Giải thuật học

Khởi tạo tham số **w** ($w_i \leftarrow$ giá trị ngẫu nhiên nhỏ)

bắt đầu

$\Delta \mathbf{w} \leftarrow 0$

với mỗi quan sát $(\mathbf{x}, d) \in D$

Dự đoán giá trị đầu ra tương ứng với dữ liệu x

Nếu (Out≠d)

$$\Delta \mathbf{w} \leftarrow \Delta \mathbf{w} + \eta(d - Out)\,\mathbf{x}$$

kết thúc vòng lặp

$\mathbf{w} \leftarrow \mathbf{w} + \Delta \mathbf{w}$

Tới khi toàn bộ dữ liệu trong D được phân loại đúng trả về **w**

23

Perceptron: Giới hạn

- Giải thuật học cho perceptron được chứng minh là hội tụ (converge) nếu:
  - Các ví dụ học là có thể phân tách tuyến tính (linearly separable)
  - Sử dụng một tốc độ học η đủ nhỏ

- Giải thuật học perceptron có thể không hội tụ nếu như các ví dụ học không thể phân tách tuyến tính (not linearly separable)

Một perceptron không thể phân lớp chính xác đối với tập học này!

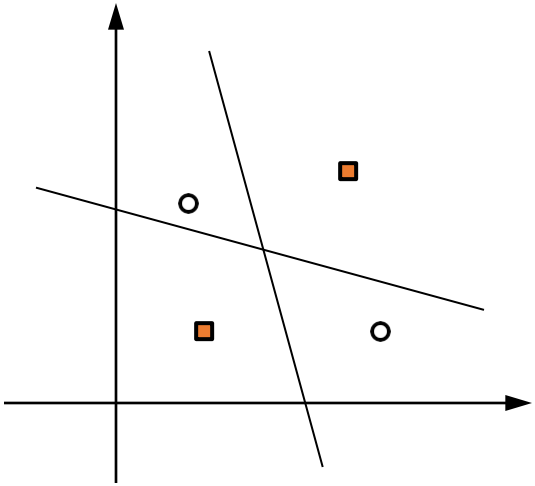

Hàm đánh giá lỗi (Loss function)

- Xét một ANN có *n* nơ-ron đầu ra
- Đối với một ví dụ học (**x**,d), giá trị **lỗi học (training error)** gây ra bởi vectơ trọng số (hiện tại) **w**:

$$E_{\mathbf{x}}(\mathbf{w}) = \frac{1}{2}\sum_{i=1}^{n}\left(d_i - Out_i\right)^2$$

- **Lỗi học** gây ra bởi vectơ trọng số (hiện tại) **w** đối với toàn bộ tập học *D*:

$$E_D(\mathbf{w}) = \frac{1}{|D|}\sum_{\mathbf{x}\in D} E_{\mathbf{x}}(\mathbf{w})$$

Tối thiểu hoá lỗi với Gradient

- **Gradient** của *E* (ký hiệu là ∇E) là một vectơ

$$\nabla E(\mathbf{w}) = \left(\frac{\partial E}{\partial w_1}, \frac{\partial E}{\partial w_2}, \ldots, \frac{\partial E}{\partial w_N} \right)$$

  - trong đó N là tổng số các trọng số (các liên kết) trong mạng

- Gradient ∇E xác định hướng gây ra việc **tăng nhanh nhất (steepest increase)** đối với giá trị lỗi *E*

- Vì vậy, hướng gây ra việc **giảm nhanh nhất (steepest decrease)** là hướng ngược với gradient của *E*

$$\Delta \mathbf{w} = -\eta \,.\, \nabla \mathrm{E}\,(\mathbf{w})\,; \qquad \Delta w_i = -\eta \frac{\partial E}{\partial w_i}, \quad \forall i = 1..N$$

- Yêu cầu: Các hàm tác động được sử dụng trong mạng phải có đạo hàm liên tục

Gradient descent: Minh họa

Không gian một chiều

E(w)

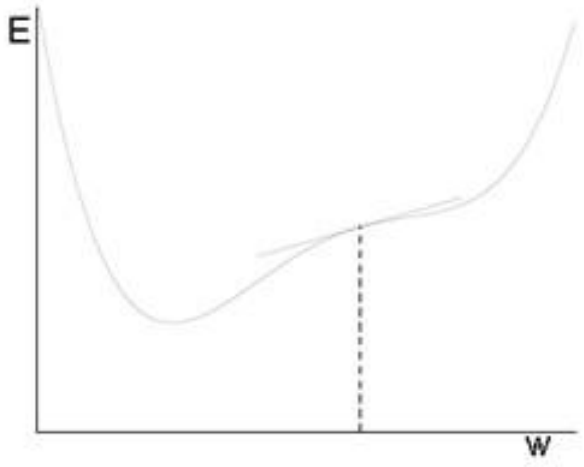

Không gian 2 chiều

$E(w_1,w_2)$

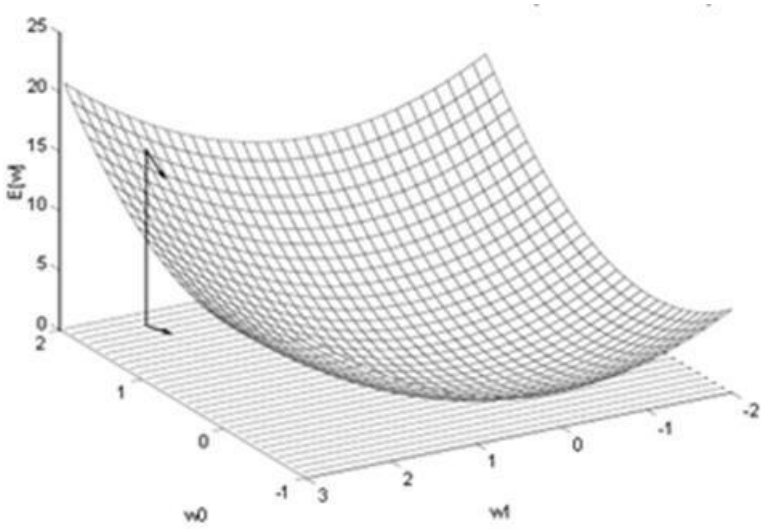

Gradient descent incremental

Khởi tạo tham số **w** ($w_i \leftarrow$ giá trị ngẫu nhiên nhỏ)

bắt đầu

Với mỗi quan sát $(\mathbf{x}, d) \in D$

Tính toán giá trị dự đoán của mạng w_i

$$w_i \leftarrow w_i - \eta(\partial E_{\mathbf{x}} / \partial w_i)$$

Kết thúc vòng lặp

Lặp lại tới khi (thoả mãn điều kiện dừng lại)

Trả về giá trị tham số **w**

Nếu ta lấy từng tập nhỏ một cách ngẫu nhiên từ **D**, ta có "mini-batch training"

Điều kiện dừng lại: Số chu kỳ học (epochs), Ngưỡng lỗi, ...

28

ANN nhiều tầng và giải thuật lan truyền ngược

- Một perceptron chỉ có thể biểu diễn một hàm phân tách tuyến tính (linear separation function)
- Một mạng nơ-ron nhiều tầng (multi-layer NN) được học bởi **giải thuật lan truyền ngược** (Back Propagation - BP) có thể biểu diễn một hàm phân tách phi tuyến phức tạp (highly non-linear separation function)
- Giải thuật học BP được sử dụng để học các trọng số của một mạng nơ-ron nhiều tầng
  - *Cấu trúc mạng cố định* (các nơ-ron và các liên kết giữa chúng là cố định)
  - Đối với mỗi nơ-ron, *hàm tác động phải có đạo hàm liên tục*
- Giải thuật BP áp dụng chiến lược *gradient descent* trong quy tắc cập nhật các trọng số
  - Để cực tiểu hóa lỗi (khác biệt) giữa các giá trị đầu ra thực tế và các giá trị đầu ra mong muốn, đối với các ví dụ học

Giải thuật học lan truyền ngược (1)

- Giải thuật học lan truyền ngược tìm kiếm một vectơ các trọng số (weights vector) giúp **cực tiểu hóa lỗi tổng thể** của hệ thống đối với tập học
- Giải thuật BP bao gồm 2 giai đoạn (bước)
  - Giai đoạn **lan truyền tiến tín hiệu (Signal forward)**. Các tín hiệu đầu vào (vectơ các giá trị đầu vào) được lan truyền tiến từ tầng đầu vào đến tầng đầu ra (đi qua các tầng ẩn)
  - Giai đoạn **lan truyền ngược lỗi (Error backward**)
    - Căn cứ vào giá trị đầu ra mong muốn của vectơ đầu vào, hệ thống tính toán giá trị lỗi
    - Bắt đầu từ tầng đầu ra, giá trị lỗi được lan truyền ngược qua mạng, từ tầng này qua tầng khác (phía trước), cho đến tầng đầu vào
    - Việc lan truyền ngược lỗi (error back-propagation) được thực hiện thông qua việc tính toán (một cách truy hồi) giá trị gradient cục bộ của mỗi nơ-ron

Giải thuật học lan truyền ngược (2)

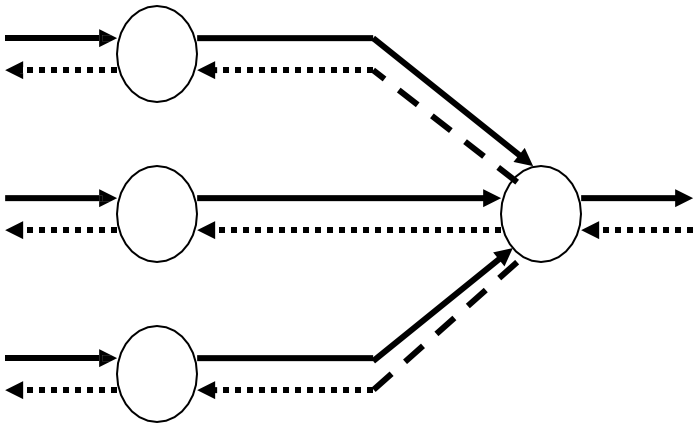

Giai đoạn lan truyền tiến tín hiệu:

- Kích hoạt (truyền tín hiệu qua) mạng

Giai đoạn lan truyền ngược lỗi:

- Tính toán lỗi ở đầu ra
- Lan truyền (ngược) lỗi

Giải thuật BP: Cấu trúc mạng

- Xét mạng nơ-ron 3 tầng (trong hình vẽ) để minh họa giải thuật học BP
- *m* tín hiệu đầu vào x_j (*j*=1..*m*)
- *l* nơ-ron tầng ẩn z_q (*q*=1..*l*)
- *n* nơ-ron đầu ra y_i (*i*=1..*n*)
- w_{qj} là trọng số của liên kết từ tín hiệu đầu vào x_j tới nơ-ron tầng ẩn z_q
- w_{iq} là trọng số của liên kết từ nơ-ron tầng ẩn z_q tới nơ-ron đầu ra y_i
- Out_q là giá trị *đầu ra (cục bộ)* của nơ-ron tầng ẩn z_q
- Out_i là giá trị *đầu ra của mạng* tương ứng với nơ-ron đầu ra y_i

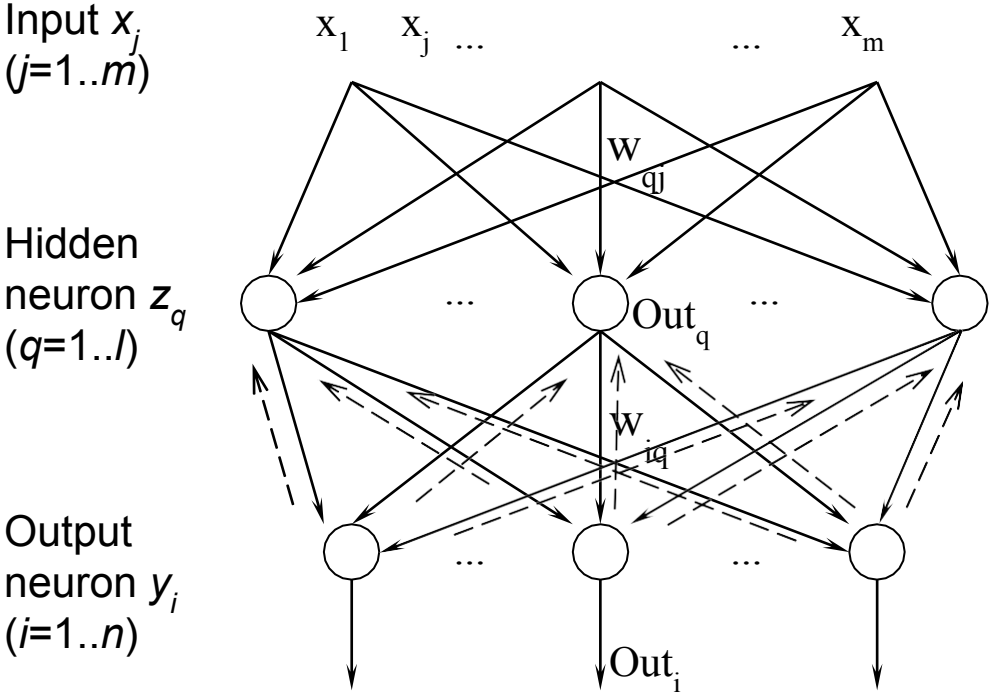

Giải thuật BP: Lan truyền tiến (1)

- Đối với mỗi ví dụ học ***x***
  - Vectơ đầu vào ***x*** được *lan truyền* từ tầng đầu vào đến tầng đầu ra
  - Mạng sẽ sinh ra một giá trị đầu ra dự đoán (predicted output) ***Out*** (là một vectơ của các giá trị Out_i, i=1..n)
- Đối với một vectơ đầu vào ***x***, một nơ-ron z_q ở tầng ẩn sẽ nhận được giá trị đầu vào tổng thể (net input) bằng:

$$Net_q = \sum_{j=1}^{m} w_{qj} x_j$$

…và sinh ra một giá trị đầu ra (cục bộ) bằng:

$$Out_q = f(Net_q) = f\left(\sum_{j=1}^{m} w_{qj} x_j\right)$$

trong đó $f()$ là hàm tác động (activation function) của nơ-ron z_q

Giải thuật BP: Lan truyền tiến (2)

- Giá trị đầu vào tổng thể (net input) của nơ-ron y_i ở tầng đầu ra

$$Net_i = \sum_{q=1}^{l} w_{iq} Out_q = \sum_{q=1}^{l} w_{iq} f\left(\sum_{j=1}^{m} w_{qj} x_j \right)$$

- Nơ-ron y_i sinh ra giá trị đầu ra (là một giá trị đầu ra của mạng)

$$Out_i = f(Net_i) = f\left(\sum_{q=1}^{l} w_{iq} Out_q \right) = f\left(\sum_{q=1}^{l} w_{iq} f\left(\sum_{j=1}^{m} w_{qj} x_j \right) \right)$$

- Vectơ các giá trị đầu ra Out_i (i=1..n) chính là giá trị đầu ra thực tế của mạng, đối với vectơ đầu vào ***x***

Giải thuật BP: Lan truyền ngược (1)

- Đối với mỗi ví dụ học ***x***
  - Các tín hiệu lỗi (error signals) do sự khác biết giữa giá trị đầu ra mong muốn ***d*** và giá trị đầu ra thực tế ***Out*** được tính toán
  - Các tín hiệu lỗi này được *lan truyền ngược (back-propagated)* từ tầng đầu ra tới các tầng phía trước, để cập nhật các trọng số (weights)
- Để xét các tín hiệu lỗi và việc lan truyền ngược của chúng, cần định nghĩa một hàm lỗi

$$E(w) = \frac{1}{2}\sum_{i=1}^{n}(d_i - Out_i)^2 = \frac{1}{2}\sum_{i=1}^{n}[d_i - f(Net_i)]^2$$

$$= \frac{1}{2}\sum_{i=1}^{n}\left[d_i - f\left(\sum_{q=1}^{l} w_{iq} Out_q\right)\right]^2$$

Giải thuật BP: Đạo hàm chuỗi

Với quy tắc đạo hàm chuỗi ta biết được rằng

$$\frac{\partial E_{total}}{\partial w_5} = \frac{\partial E_{total}}{\partial out_{o1}} * \frac{\partial out_{o1}}{\partial net_{o1}} * \frac{\partial net_{o1}}{\partial w_5}$$

Trực quan hoá bước lan truyền ngược:

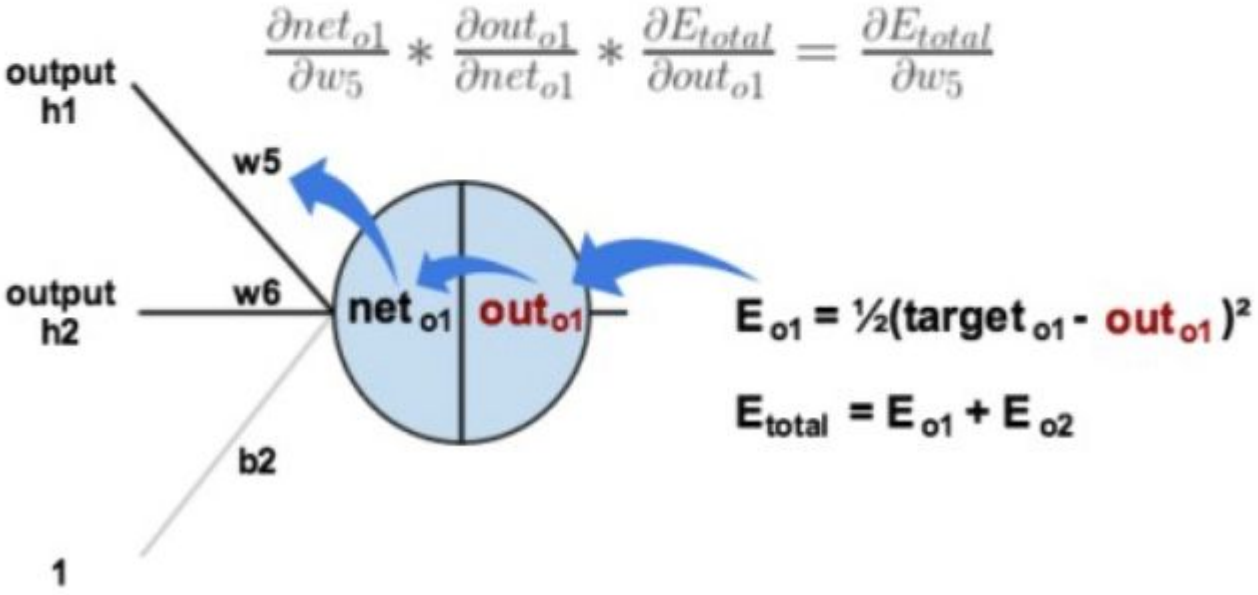

Giải thuật BP: Lan truyền ngược (2)

- Theo phương pháp gradient-descent, các trọng số của các liên kết **từ tầng ẩn tới tầng đầu ra** được cập nhật bởi

$$\Delta w_{iq} = -\eta \frac{\partial E}{\partial w_{iq}}$$

- Sử dụng quy tắc chuỗi đạo hàm đối với $\partial E/\partial w_{iq}$, ta có

$$\Delta w_{iq} = -\eta \left[\frac{\partial E}{\partial Out_i}\right]\left[\frac{\partial Out_i}{\partial Net_i}\right]\left[\frac{\partial Net_i}{\partial w_{iq}}\right] = \eta\left[d_i - Out_i\right]\left[f'(Net_i)\right]\left[Out_q\right] = \eta\delta_i Out_q$$

(Lưu ý: dấu "–" đã được kết hợp với giá trị $\partial E/\partial Out_i$)

- ***i*** là **tín hiệu lỗi (error signal)** của nơ-ron y_i ở <u>tầng đầu ra</u>

$$\delta_i = -\frac{\partial E}{\partial Net_i} = -\left[\frac{\partial E}{\partial Out_i}\right]\left[\frac{\partial Out_i}{\partial Net_i}\right] = \left[d_i - Out_i\right]\left[f'(Net_i)\right]$$

trong đó Net_i là đầu vào tổng thể (net input) của nơ-ron y_i ở <u>tầng đầu ra</u>, và $f'(Net_i)=f(Net_i)/Net_i$

Giải thuật BP: Lan truyền ngược (4)

- Áp dụng quy tắc chuỗi đạo hàm, ta có

$$\Delta w_{qj} = \eta \sum_{i=1}^{n} \left[(d_i - Out_i) f'(Net_i) w_{iq} \right] f'(Net_q) x_j$$

$$= \eta \sum_{i=1}^{n} \left[\delta_i w_{iq} \right] f'(Net_q) x_j = \eta \delta_q x_j$$

- δ_q là **tín hiệu lỗi (error signal)** của nơ-ron z_q ở tầng ẩn

$$\delta_q = -\frac{\partial E}{\partial Net_q} = -\left[\frac{\partial E}{\partial Out_q} \right] \left[\frac{\partial Out_q}{\partial Net_q} \right] = f'(Net_q) \sum_{i=1}^{n} \delta_i w_{iq}$$

trong đó Net_q là đầu vào tổng thể (net input) của nơ-ron z_q ở tầng ẩn, và $f'(Net_q) = \partial f(Net_q)/\partial Net_q$

Giải thuật BP: Lan truyền ngược (5)

- Theo các công thức tính các tín hiệu lỗi δ_i và δ_q đã nêu, thì *tín hiệu lỗi của một nơ-ron ở tầng ẩn* **khác với** *tín hiệu lỗi của một nơ-ron ở tầng đầu ra*
- Do sự khác biệt này, thủ tục cập nhật trọng số trong giải thuật BP còn được gọi là *quy tắc học delta tổng quát*
- Tín hiệu lỗi δ_q của nơ-ron z_q ở tầng ẩn được xác định bởi
  - Các tín hiệu lỗi δ_i của các nơ-ron y_i ở tầng đầu ra (mà nơ-ron z_q liên kết tới)
  - Các hệ số chính là các trọng số w_{iq}

Giải thuật BP: Lan truyền ngược (6)

- Quá trình tính toán tín hiệu lỗi (error signals) như trên có thể được mở rộng (khái quát) dễ dàng đối với mạng nơ-ron có nhiều hơn 1 tầng ẩn (hidden layer)
- Dạng tổng quát của quy tắc cập nhật trọng số trong giải thuật BP là:

$$\Delta w_{ab} = \eta \delta_a x_b$$

  - *b* và *a* là 2 chỉ số tương ứng với 2 đầu của liên kết (*b*→*a*) (từ một nơ-ron (hoặc tín hiệu đầu vào) *b* đến nơ-ron *a*)
  - x_b là giá trị đầu ra của nơ-ron ở tầng ẩn (hoặc tín hiệu đầu vào) *b*
  - δ_a là tín hiệu lỗi của nơ-ron *a*

Back_propagation_incremental(D, η)

- Mạng nơ-ron gồm Q tầng, q = 1,2,...,Q
- ${}^{q}Net_i$ và ${}^{q}Out_i$ là đầu vào tổng thể (net input) và giá trị đầu ra của nơ-ron i ở tầng q
- Mạng có m tín hiệu đầu vào và n nơ-ron đầu ra
- ${}^{q}w_{ij}$ là trọng số của liên kết từ nơ-ron j ở tầng $(q-1)$ đến nơ-ron i ở tầng q

Bước 0 (Khởi tạo)

Chọn ngưỡng lỗi $E_{threshold}$ (giá trị lỗi có thể chấp nhận được)

Khởi tạo giá trị ban đầu của các trọng số với các giá trị nhỏ ngẫu nhiên

Gán E=0

Back propagation incremental

Bước 1 (Bắt đầu một chu kỳ học)

Áp dụng vectơ đầu vào của ví dụ học *k* đối với tầng đầu vào (*q*=1)

$$^{q}Out_i = {}^{1}Out_i = x_i^{(k)}, \forall i$$

Bước 2 (Lan truyền tiến)

Lan truyền tiến các tín hiệu đầu vào qua mạng, cho đến khi nhận được các giá trị đầu ra của mạng (ở tầng đầu ra) $^{Q}Out_i$

$$^{q}Out_i = f\left(^{q}Net_i\right) = f\left(\sum_j {}^{q}w_{ij}\,{}^{q-1}Out_j\right)$$

Bước 3 Tính toán lỗi đầu ra của mạng và tín hiệu lỗi *Qi* của mỗi nơ-ron ở tầng đầu ra

$$E = E + \frac{1}{2}\sum_{i=1}^{n}(d_i^{(k)} - {}^{Q}Out_i)^2$$

$$^{Q}\delta_i = (d_i^{(k)} - {}^{Q}Out_i) f'({}^{Q}Net_i)$$

Back_propagation_incremental(D, η)

Bước 4 (Lan truyền ngược lỗi)

Lan truyền ngược lỗi để cập nhật các trọng số và tính toán các tín hiệu lỗi $^{q-1}\delta_i$ cho các tầng phía trước

Bước 5 (Kiểm tra kết thúc một chu kỳ học – epoch)

Kiểm tra xem toàn bộ tập học đã được sử dụng (đã xong một chu kỳ học – epoch)

Nếu toàn bộ tập học đã được dùng, chuyển đến Bước 6; ngược lại, chuyển đến Bước 1

Bước 6 (Kiểm tra lỗi tổng thể)

Nếu lỗi tổng thể E nhỏ hơn ngưỡng lỗi chấp nhận được ($<E_{threshold}$), thì quá trình học kết thúc và trả về các trọng số học được;

Ngược lại, gán lại E=0, và bắt đầu một chu kỳ học mới (quay về Bước 1)

Giải thuật BP: Lan truyền tiến (1)

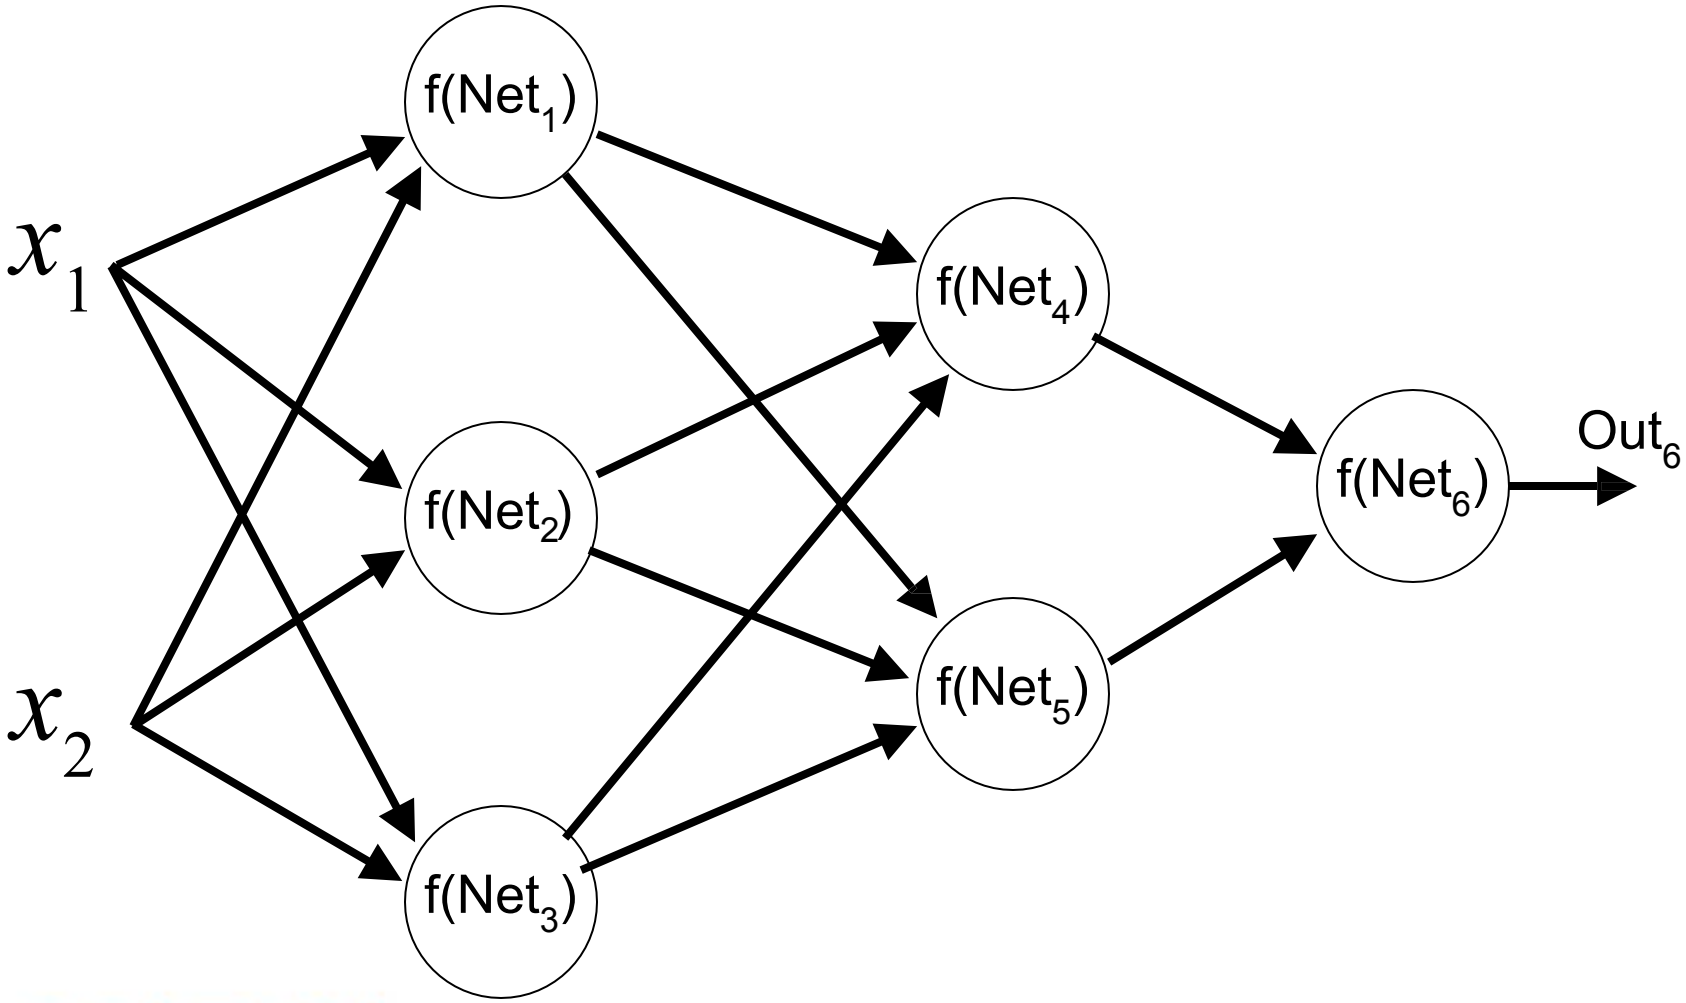

Giải thuật BP: Lan truyền tiến (2)

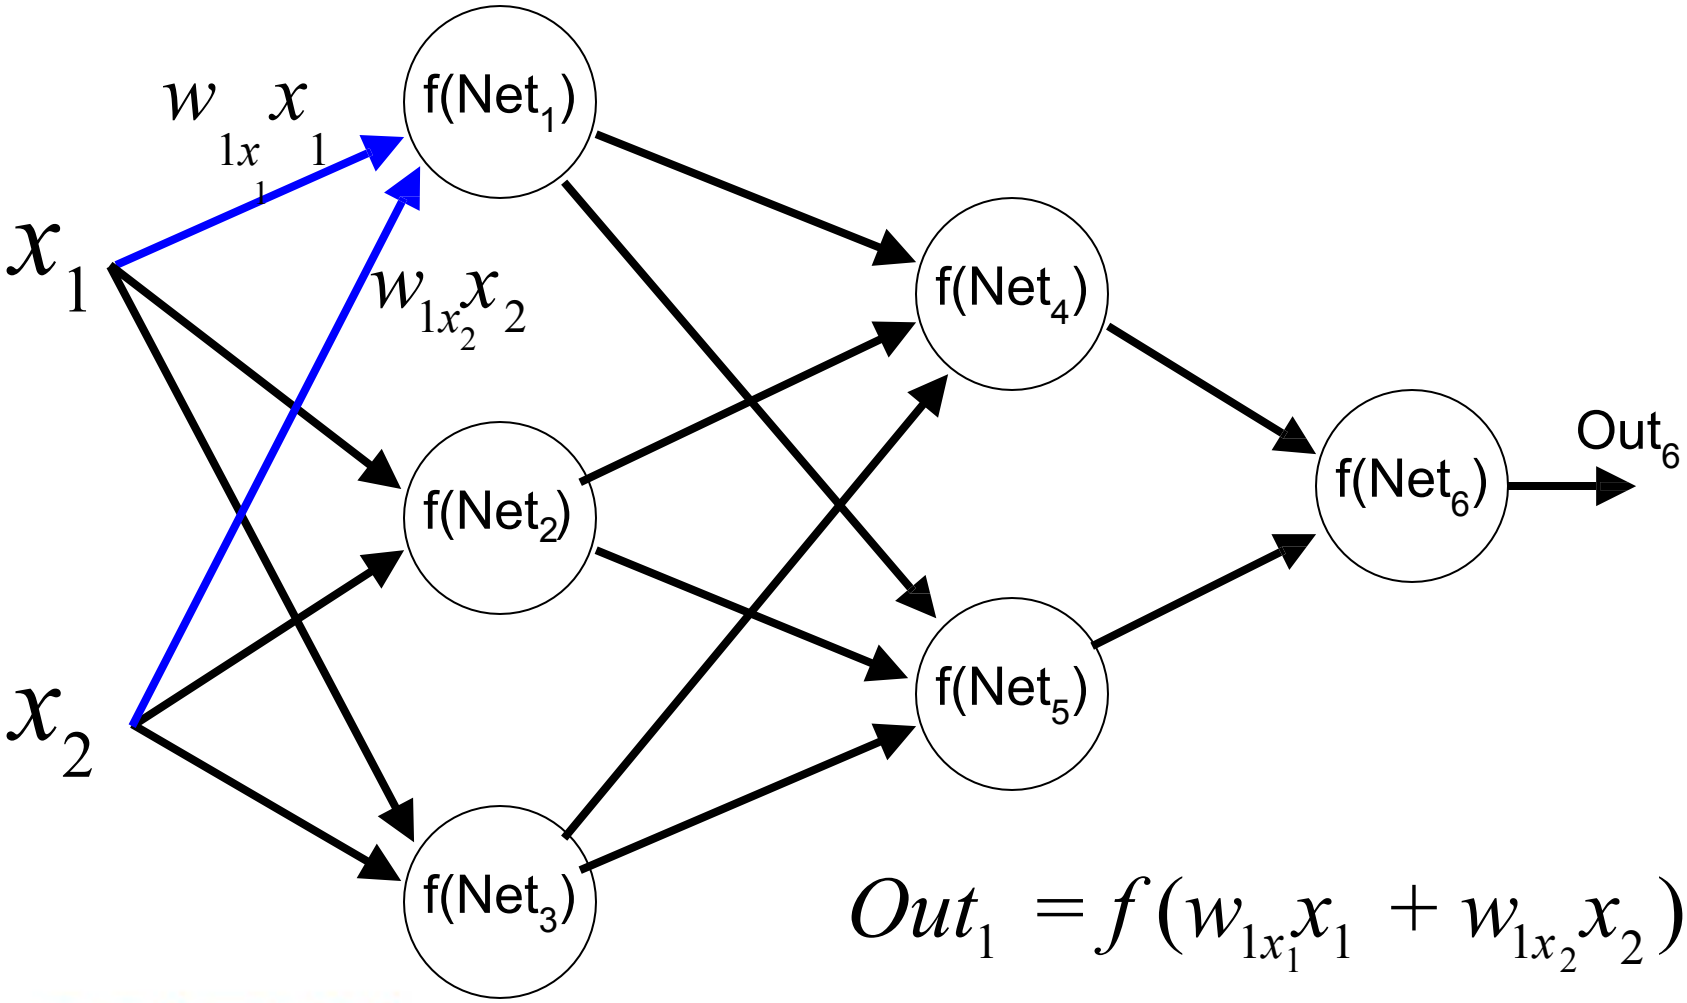

Giải thuật BP: Lan truyền tiến (3)

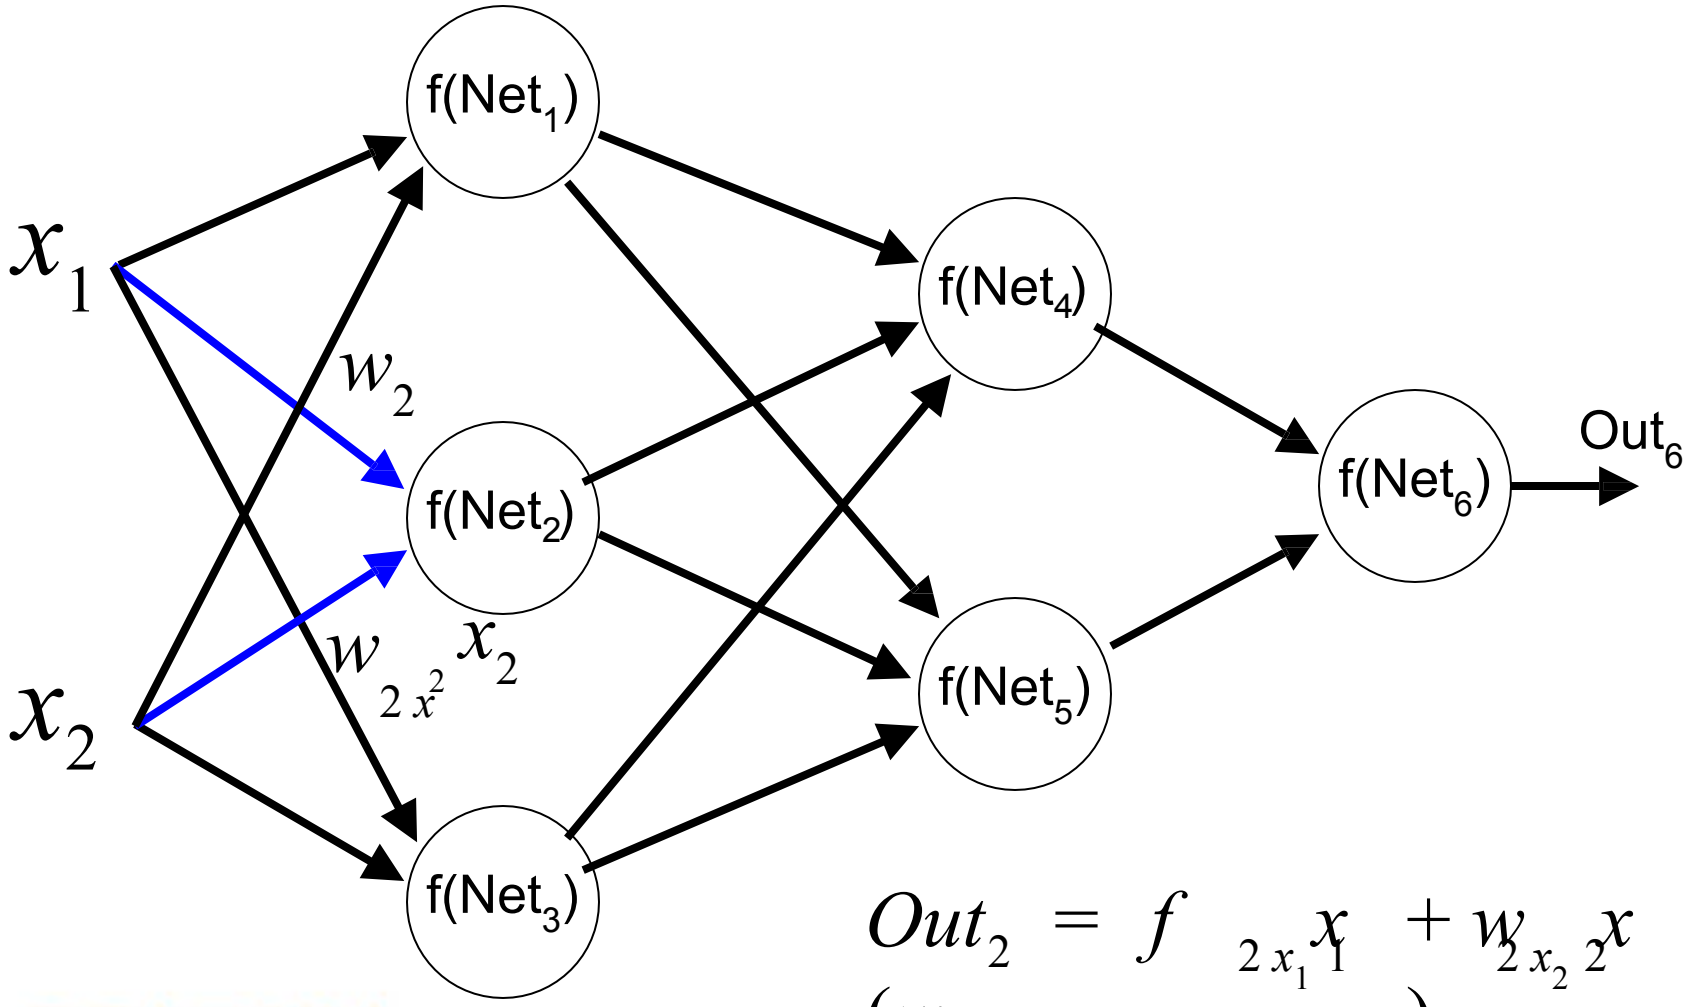

$$Out_2 = f(w_{2x_1} x_1 + w_{2x_2} x_2)$$

Giải thuật BP: Lan truyền tiến (4)

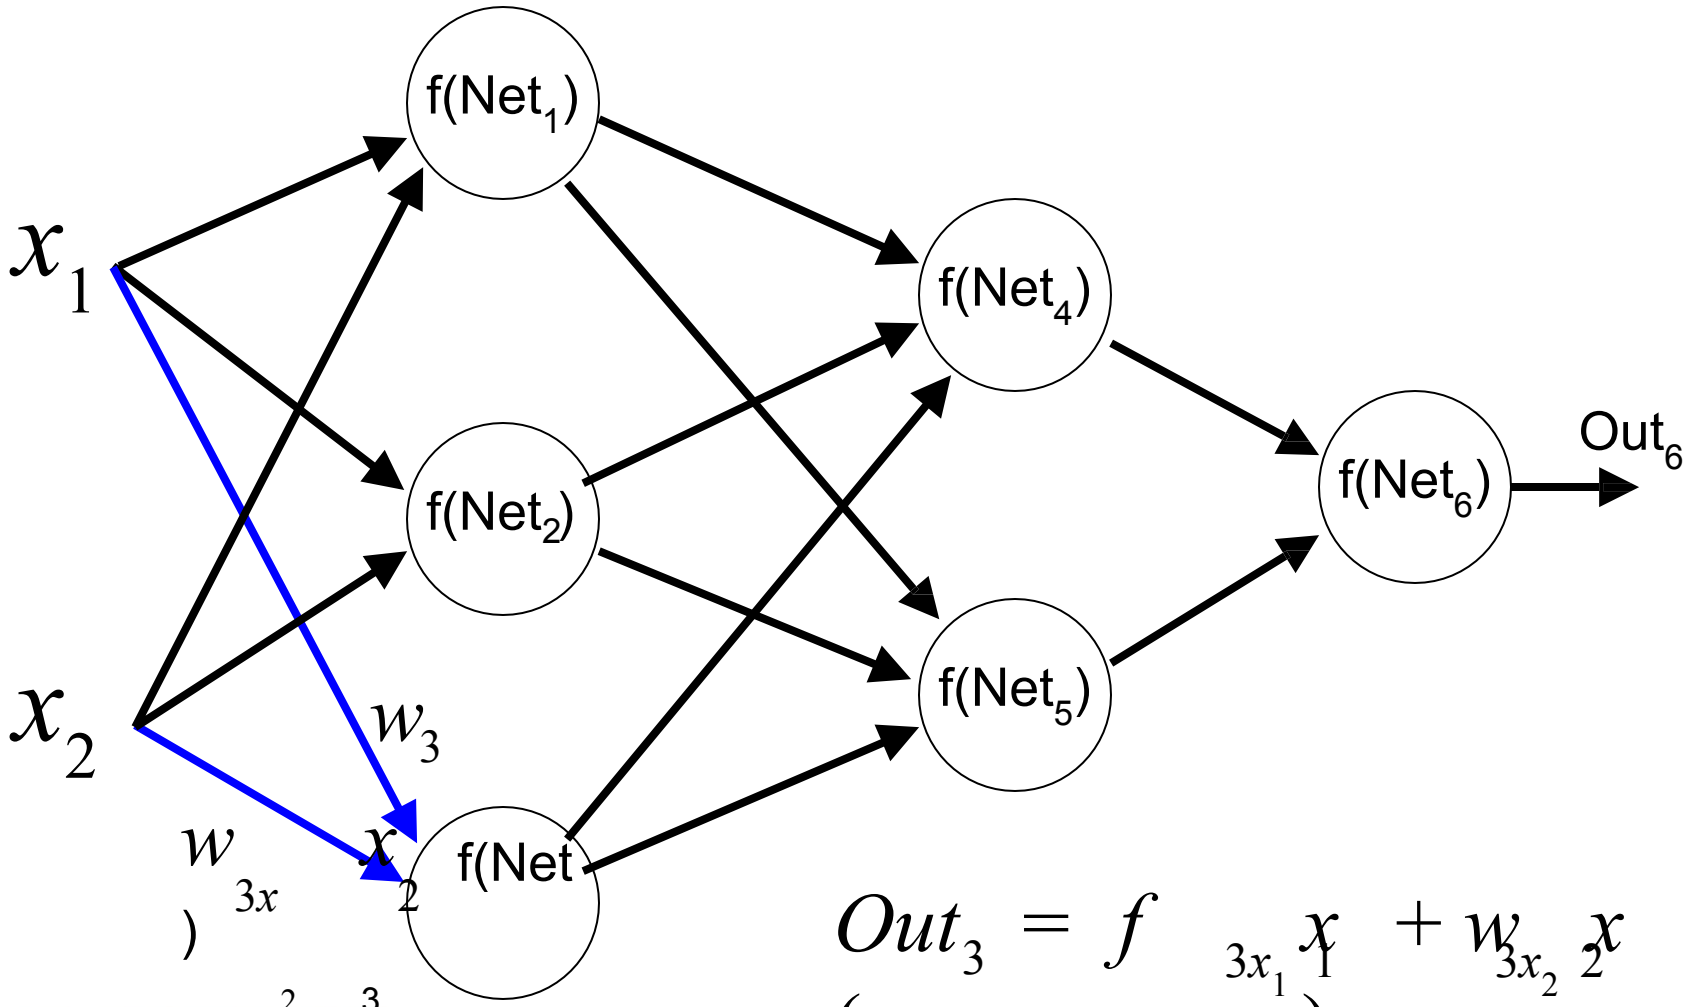

$$Out_3 = f(w_{3x_1} x_1 + w_{3x_2} x_2)$$

Giải thuật BP: Lan truyền tiến (5)

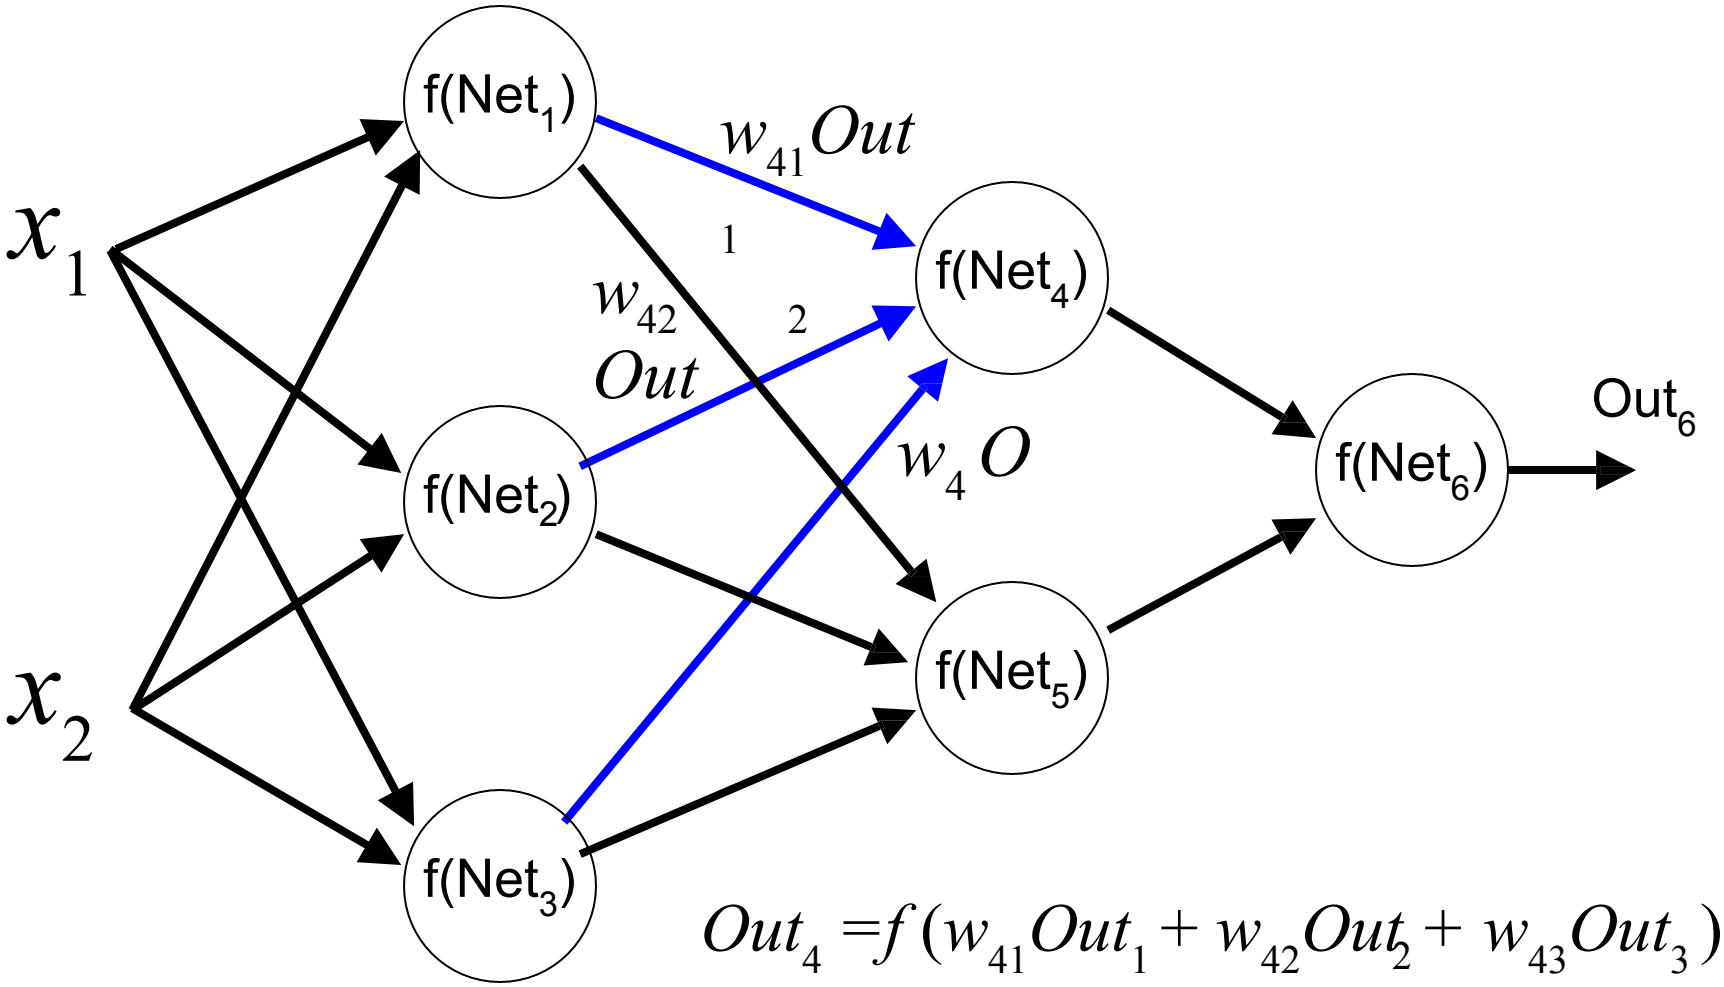

$$Out_4 = f(w_{41}Out_1 + w_{42}Out_2 + w_{43}Out_3)$$

Giải thuật BP: Lan truyền tiến (6)

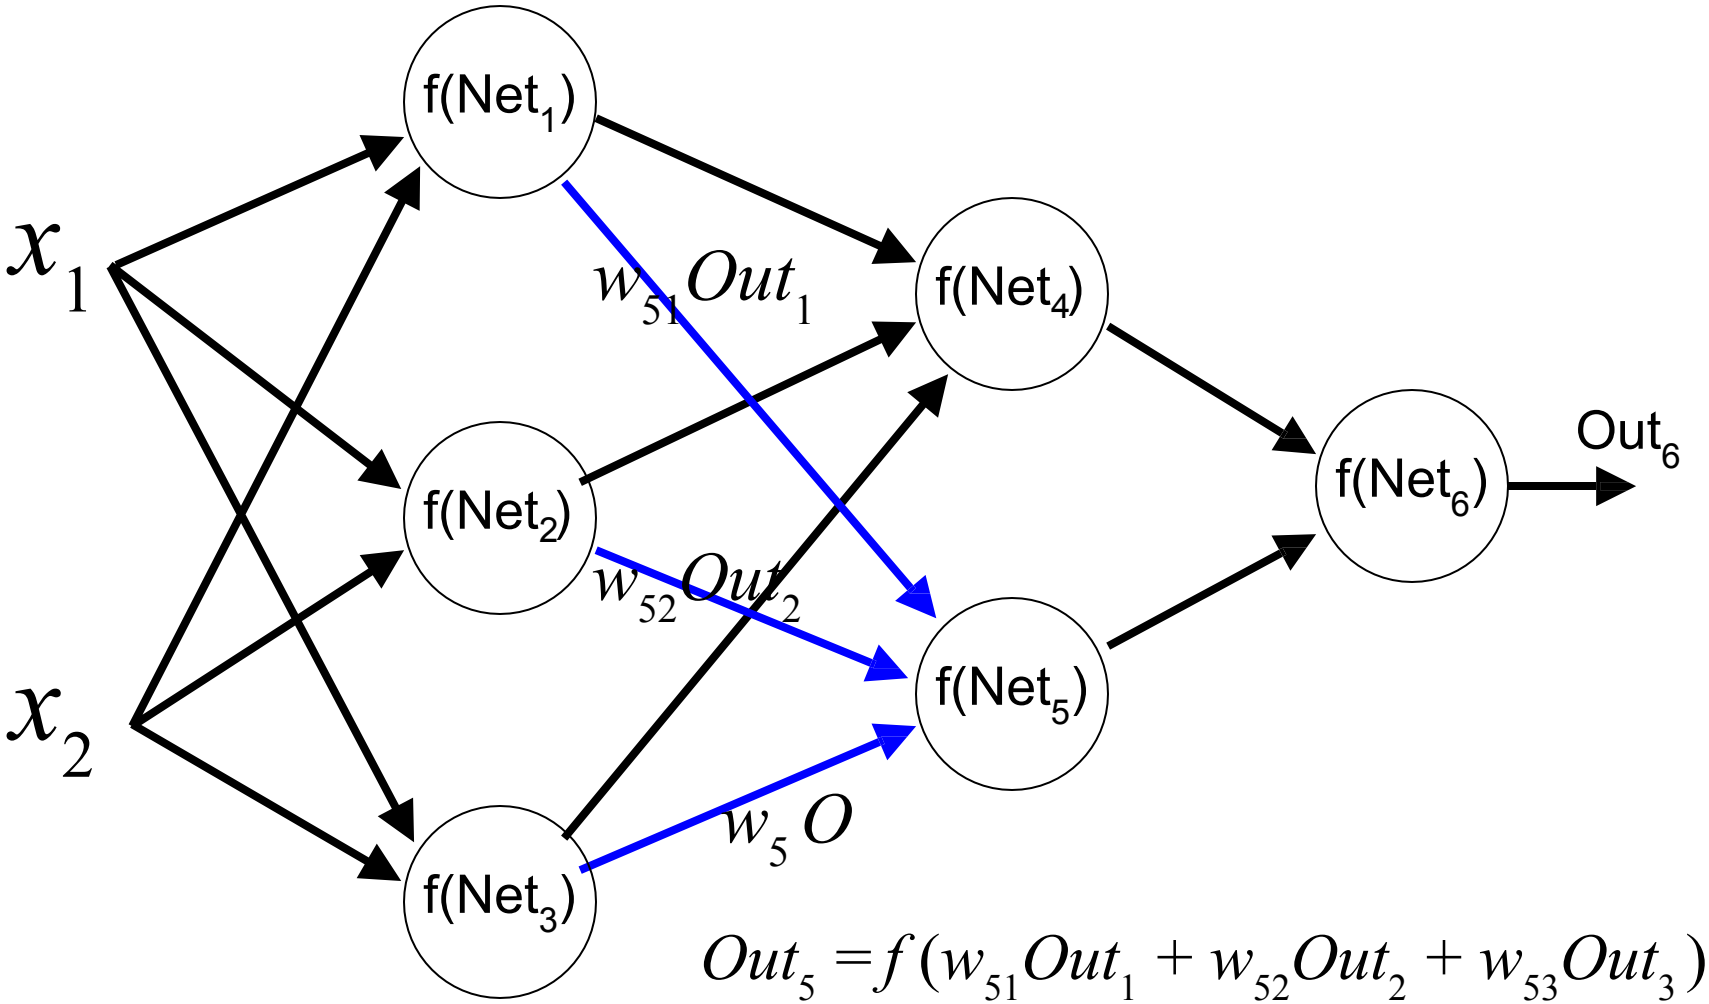

$$Out_5 = f(w_{51}Out_1 + w_{52}Out_2 + w_{53}Out_3)$$

Giải thuật BP: Lan truyền tiến (7)

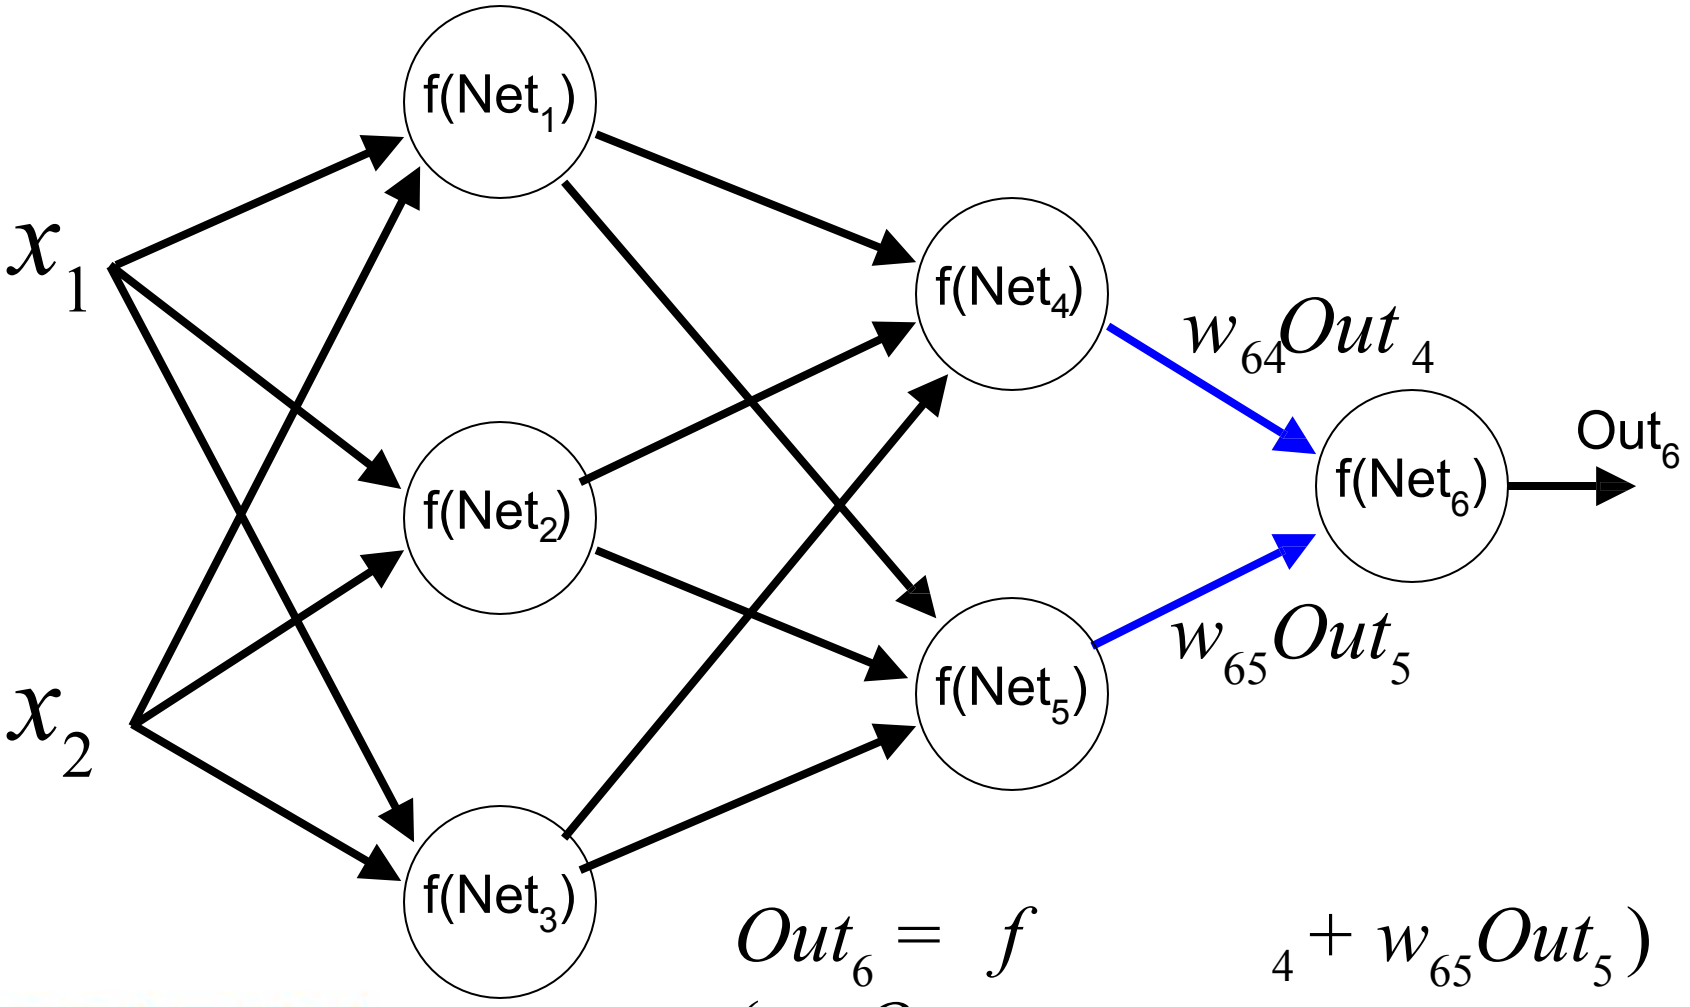

$$Out_6 = f(w_{64}Out_4 + w_{65}Out_5)$$

Giải thuật BP: Tính toán lỗi

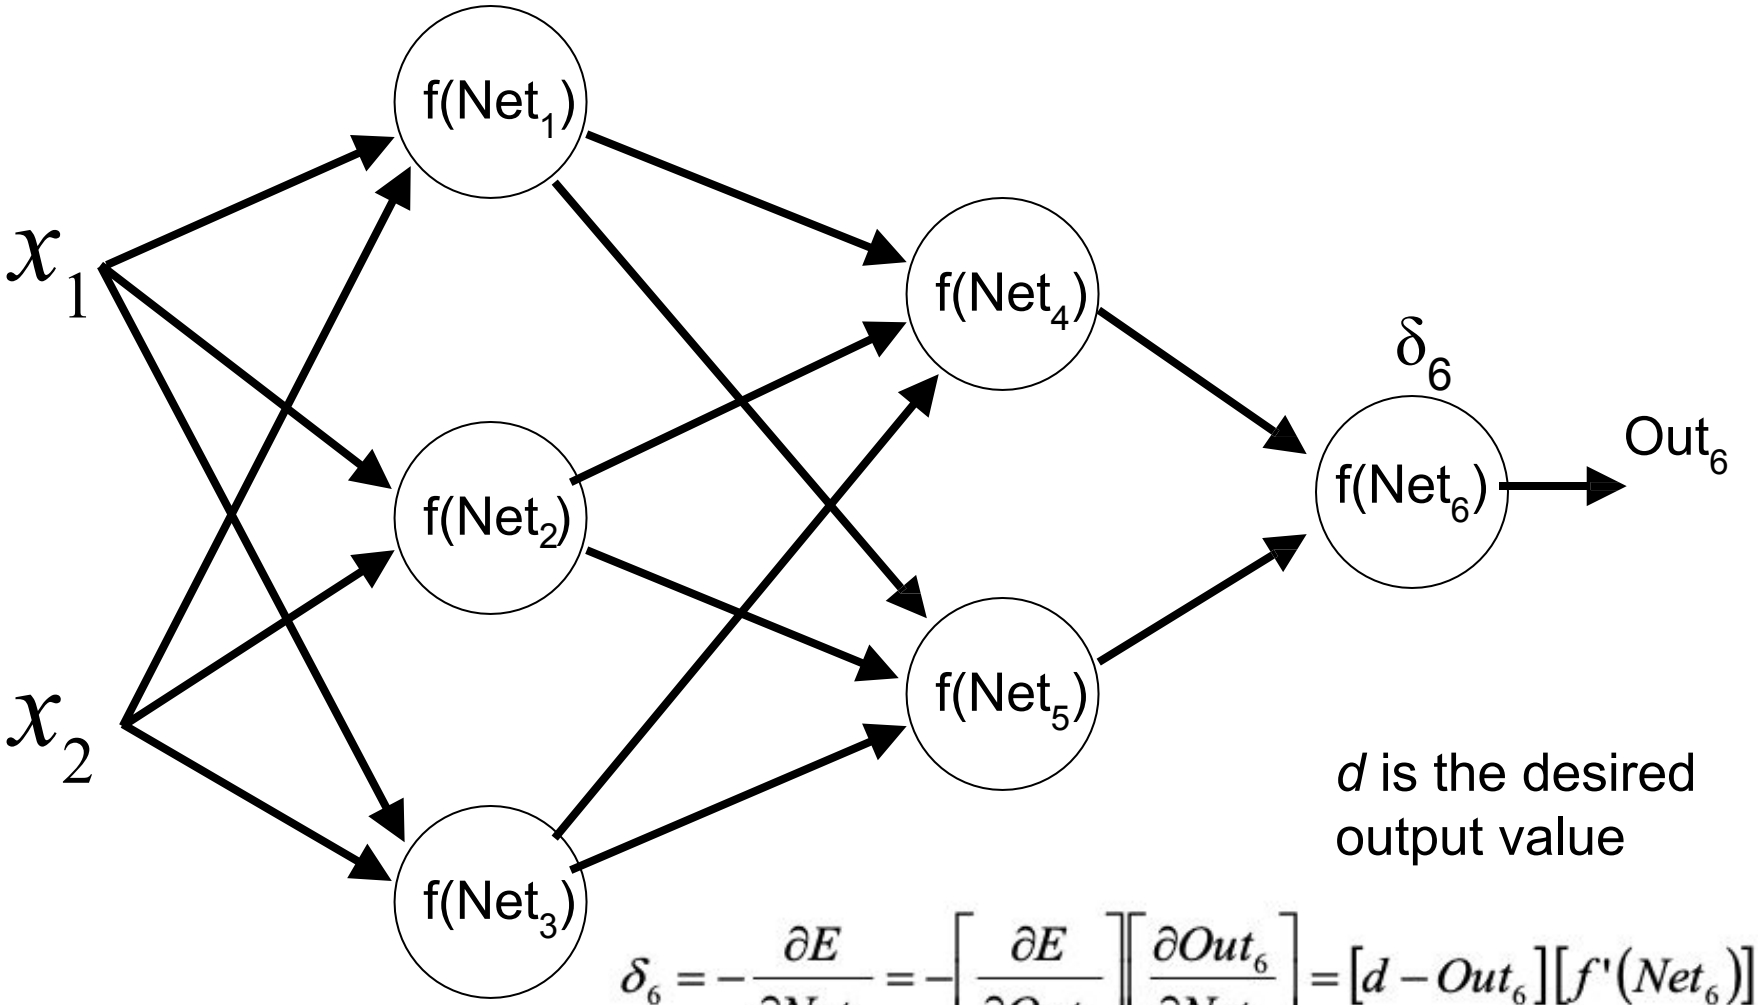

d is the desired output value

$$\delta_6 = -\frac{\partial E}{\partial Net_6} = -\left[\frac{\partial E}{\partial Out_6}\right]\left[\frac{\partial Out_6}{\partial Net_6}\right] = [d - Out_6][f'(Net_6)]$$

COLE.VN
Connecting knowledge

Giải thuật BP: Lan truyền ngược (1)

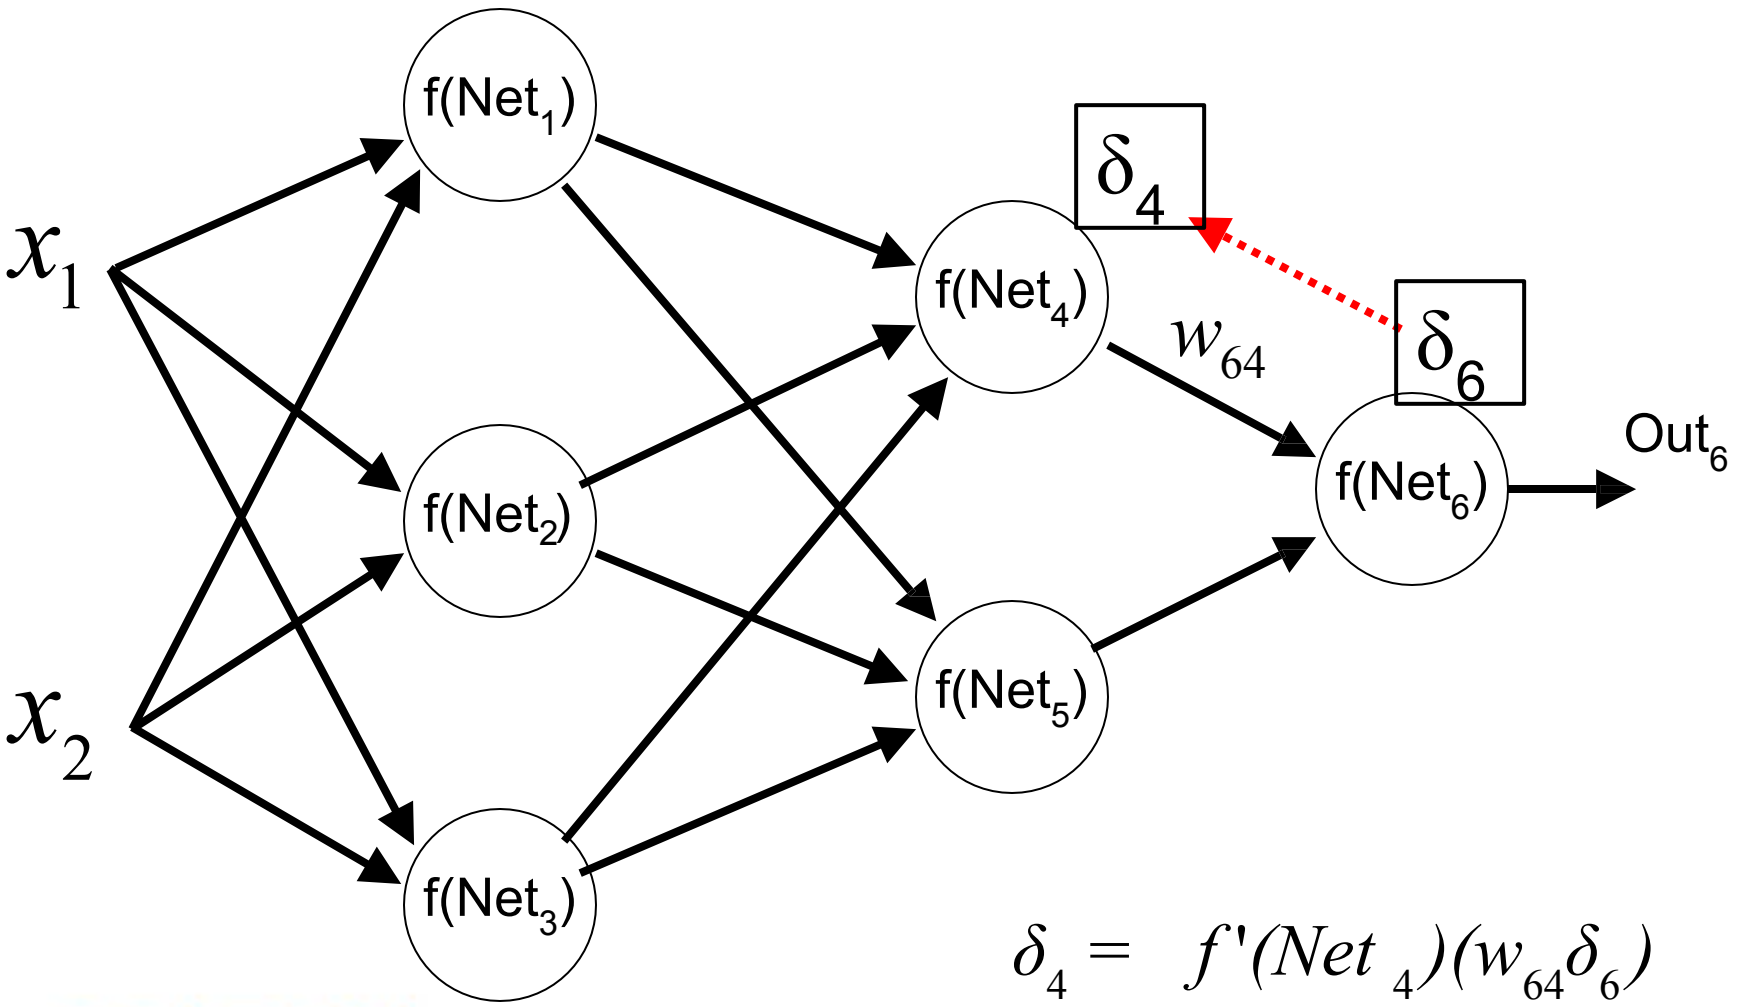

$$\delta_4 = f'(Net_4)(w_{64}\delta_6)$$

Giải thuật BP: Lan truyền ngược (2)

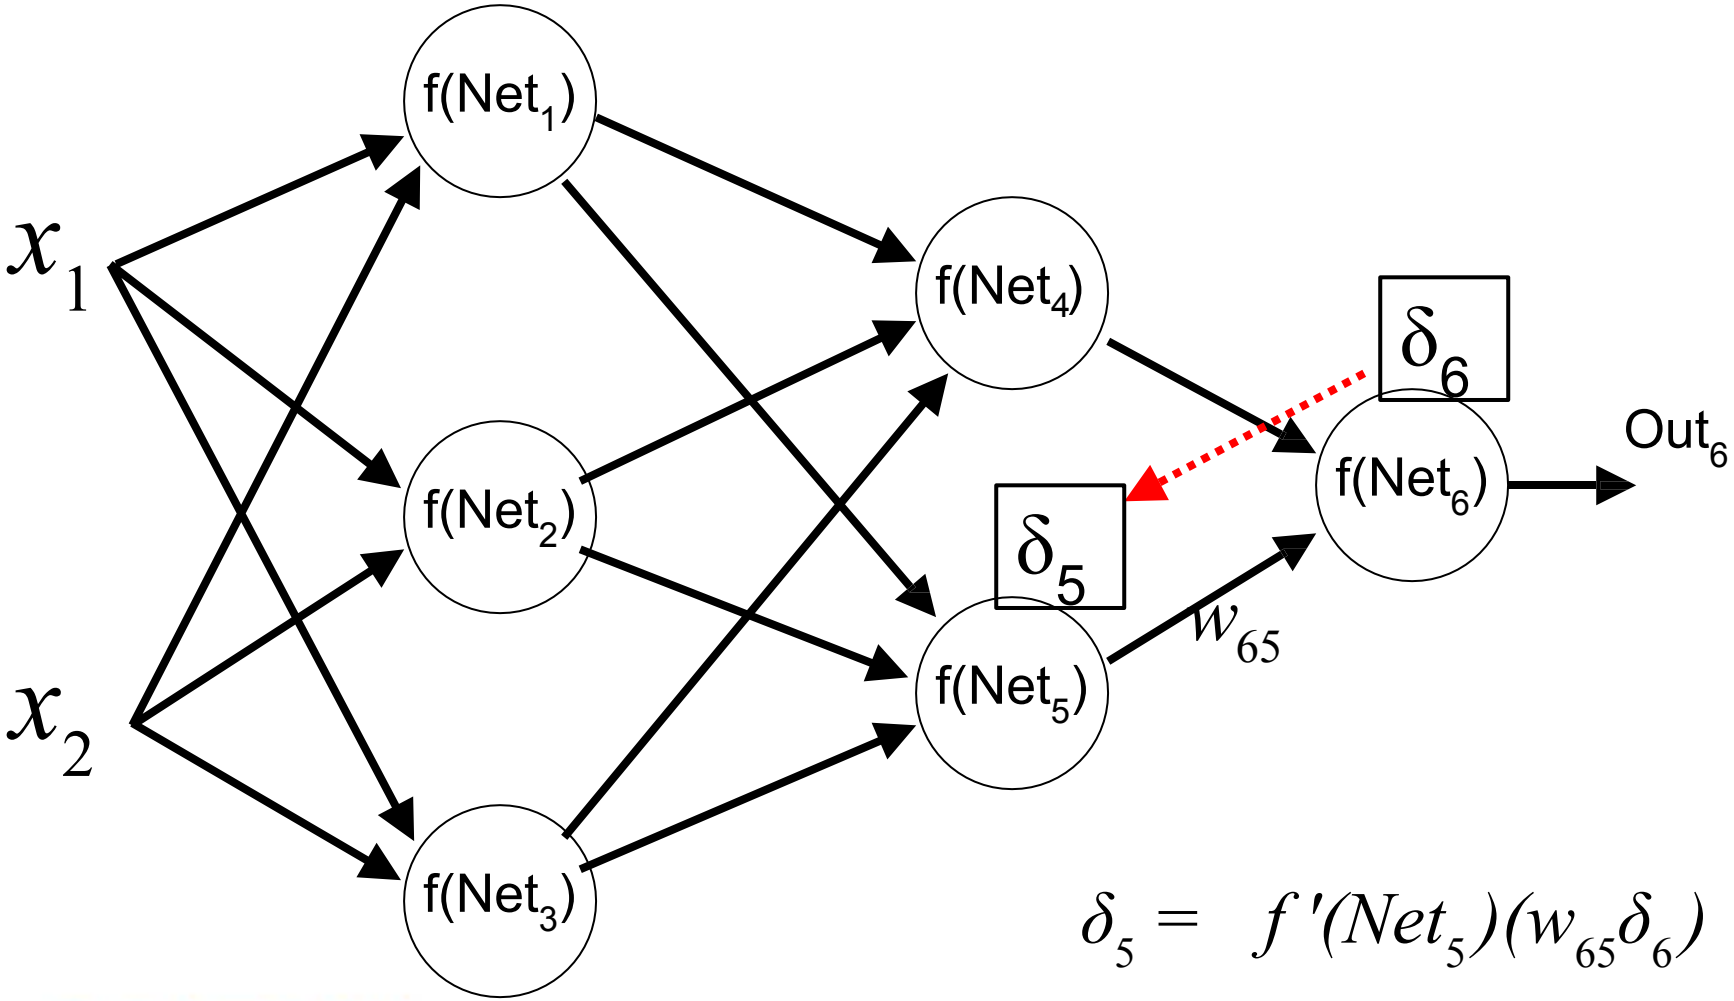

$$\delta_5 = f'(Net_5)(w_{65}\delta_6)$$

Giải thuật BP: Lan truyền ngược (3)

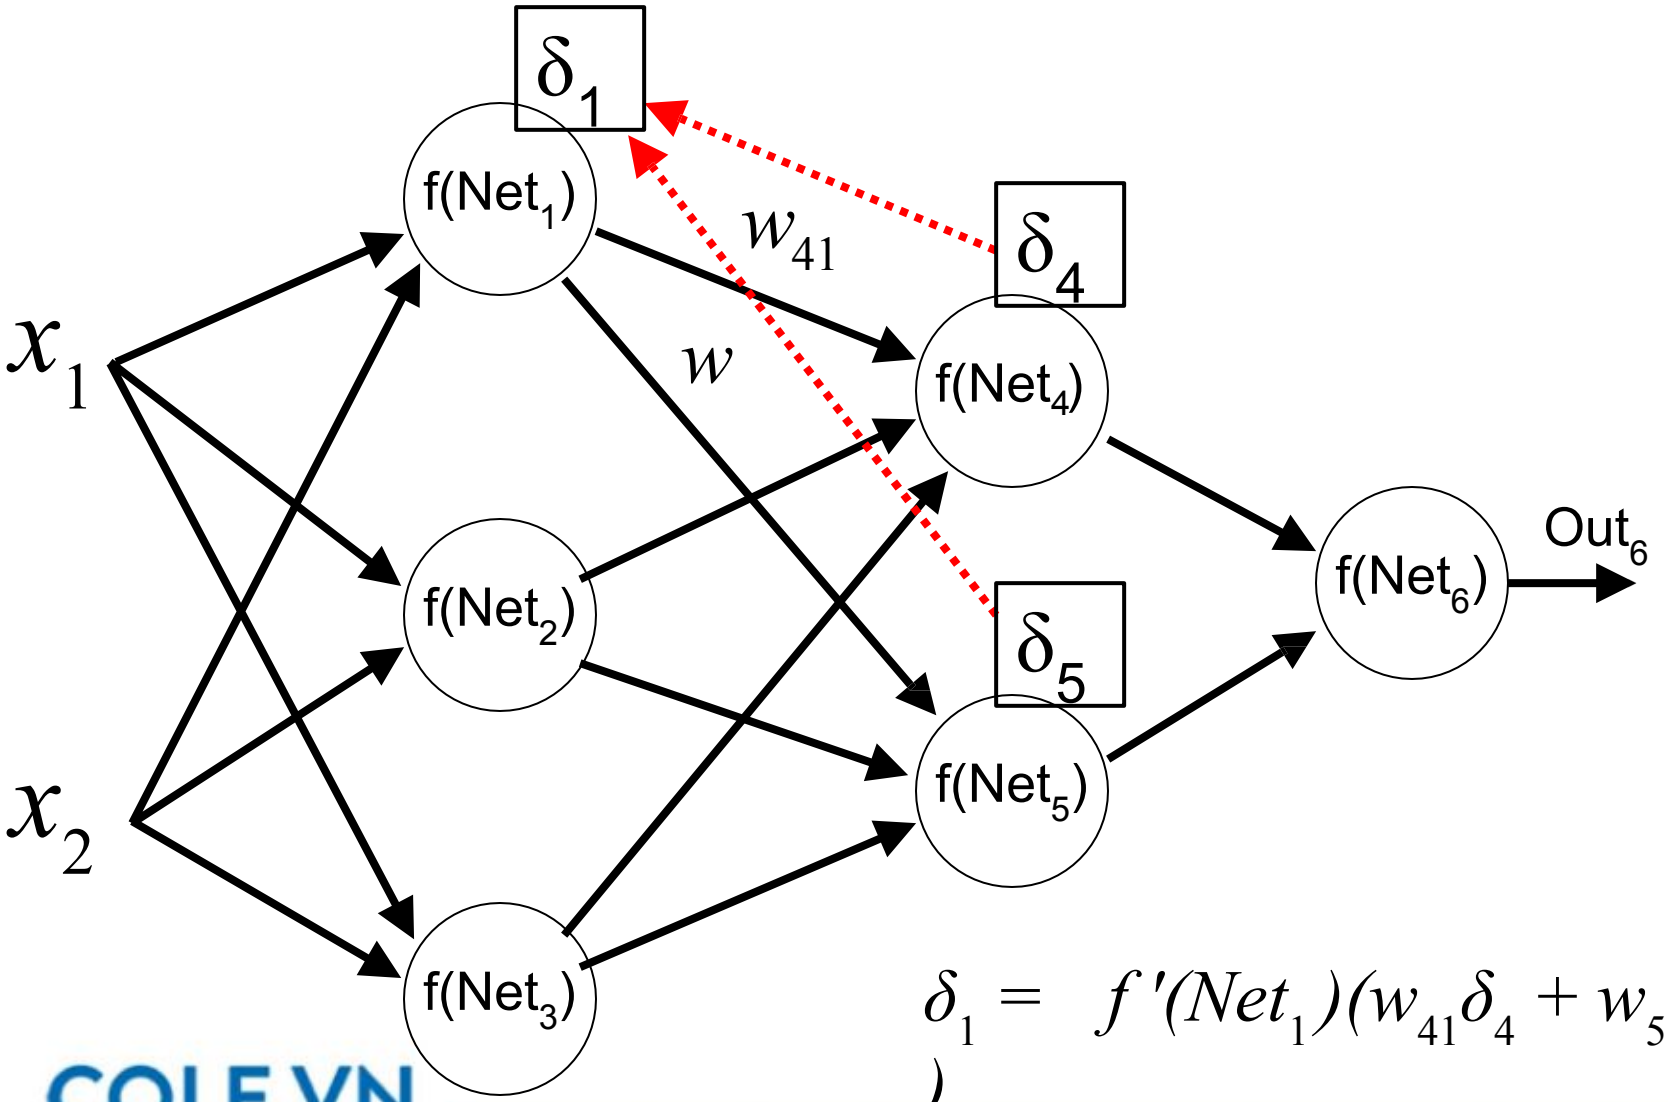

$$\delta_1 = f'(Net_1)(w_{41}\delta_4 + w_{51}\delta_5)$$

Giải thuật BP: Lan truyền ngược (4)

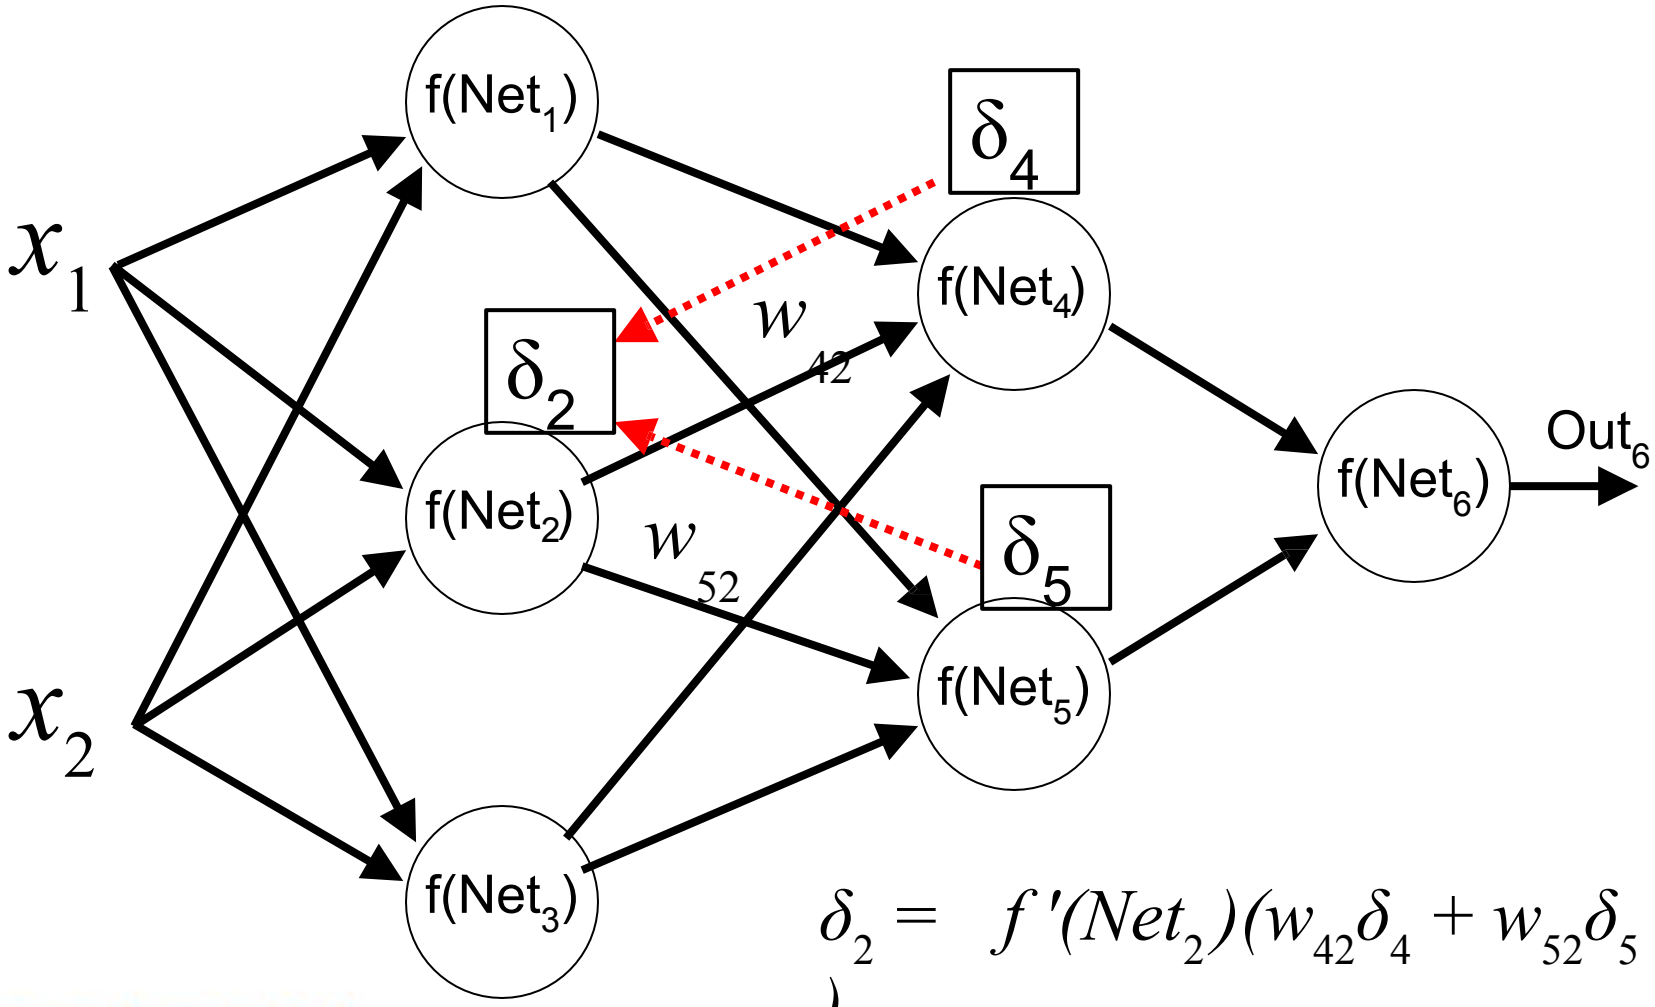

$$\delta_2 = f'(Net_2)(w_{42}\delta_4 + w_{52}\delta_5)$$

Giải thuật BP: Lan truyền ngược (5)

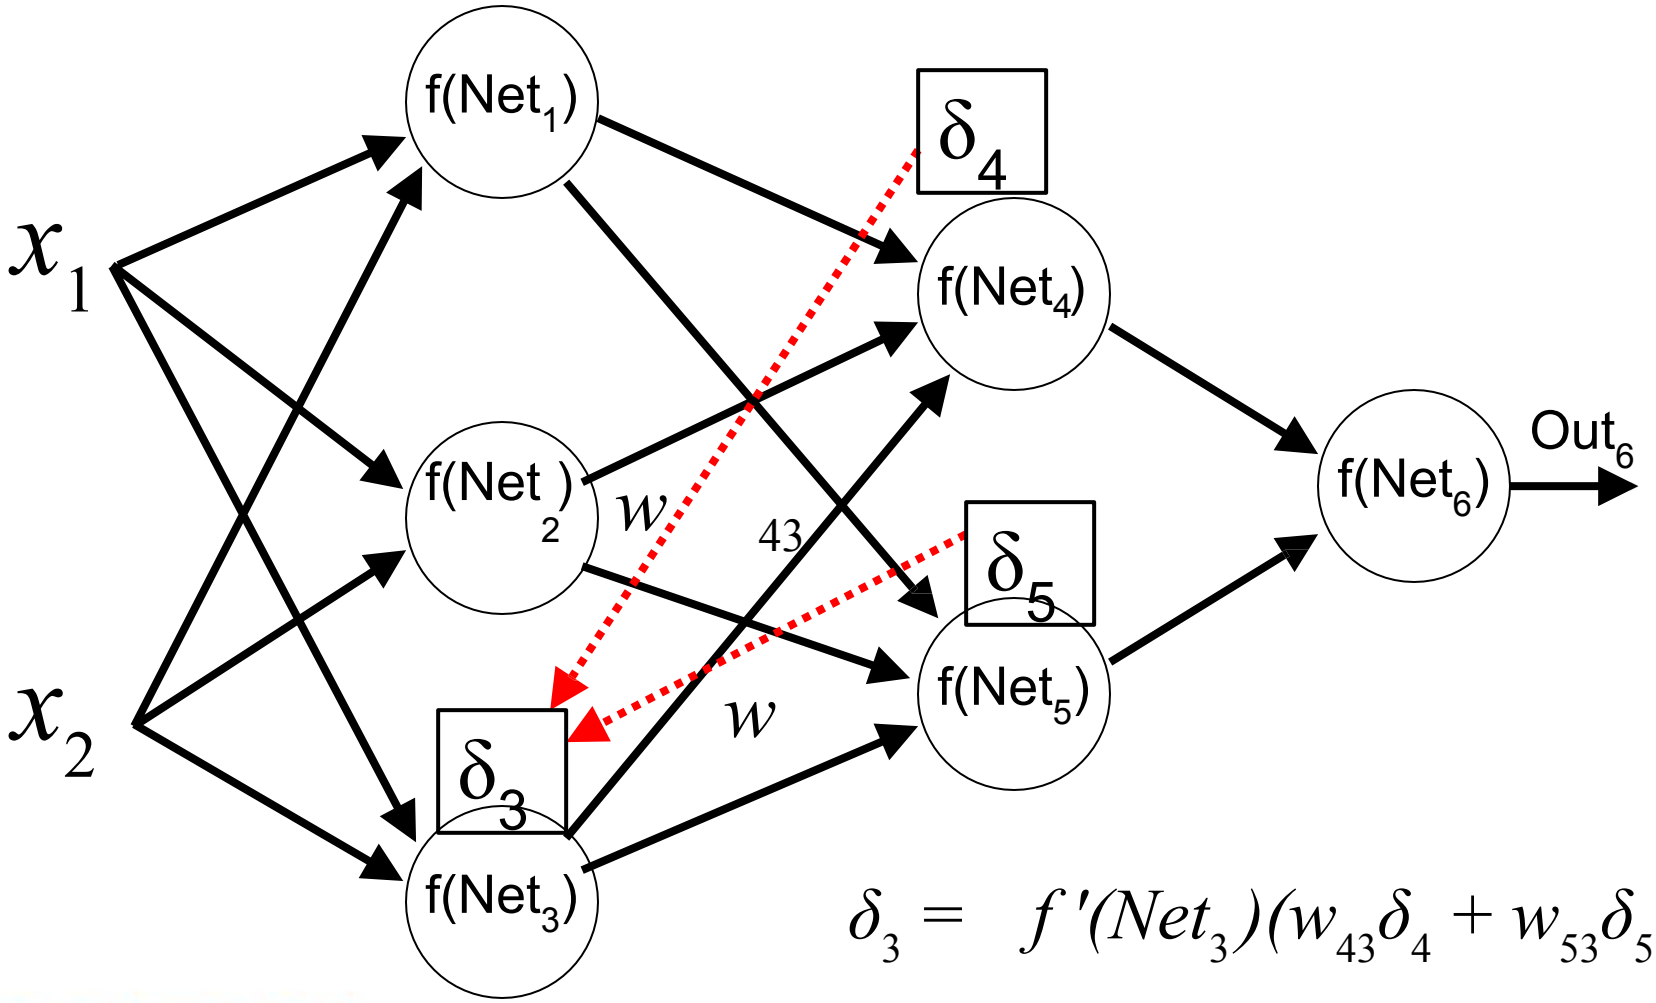

Giải thuật BP: Cập nhật trọng số (1)

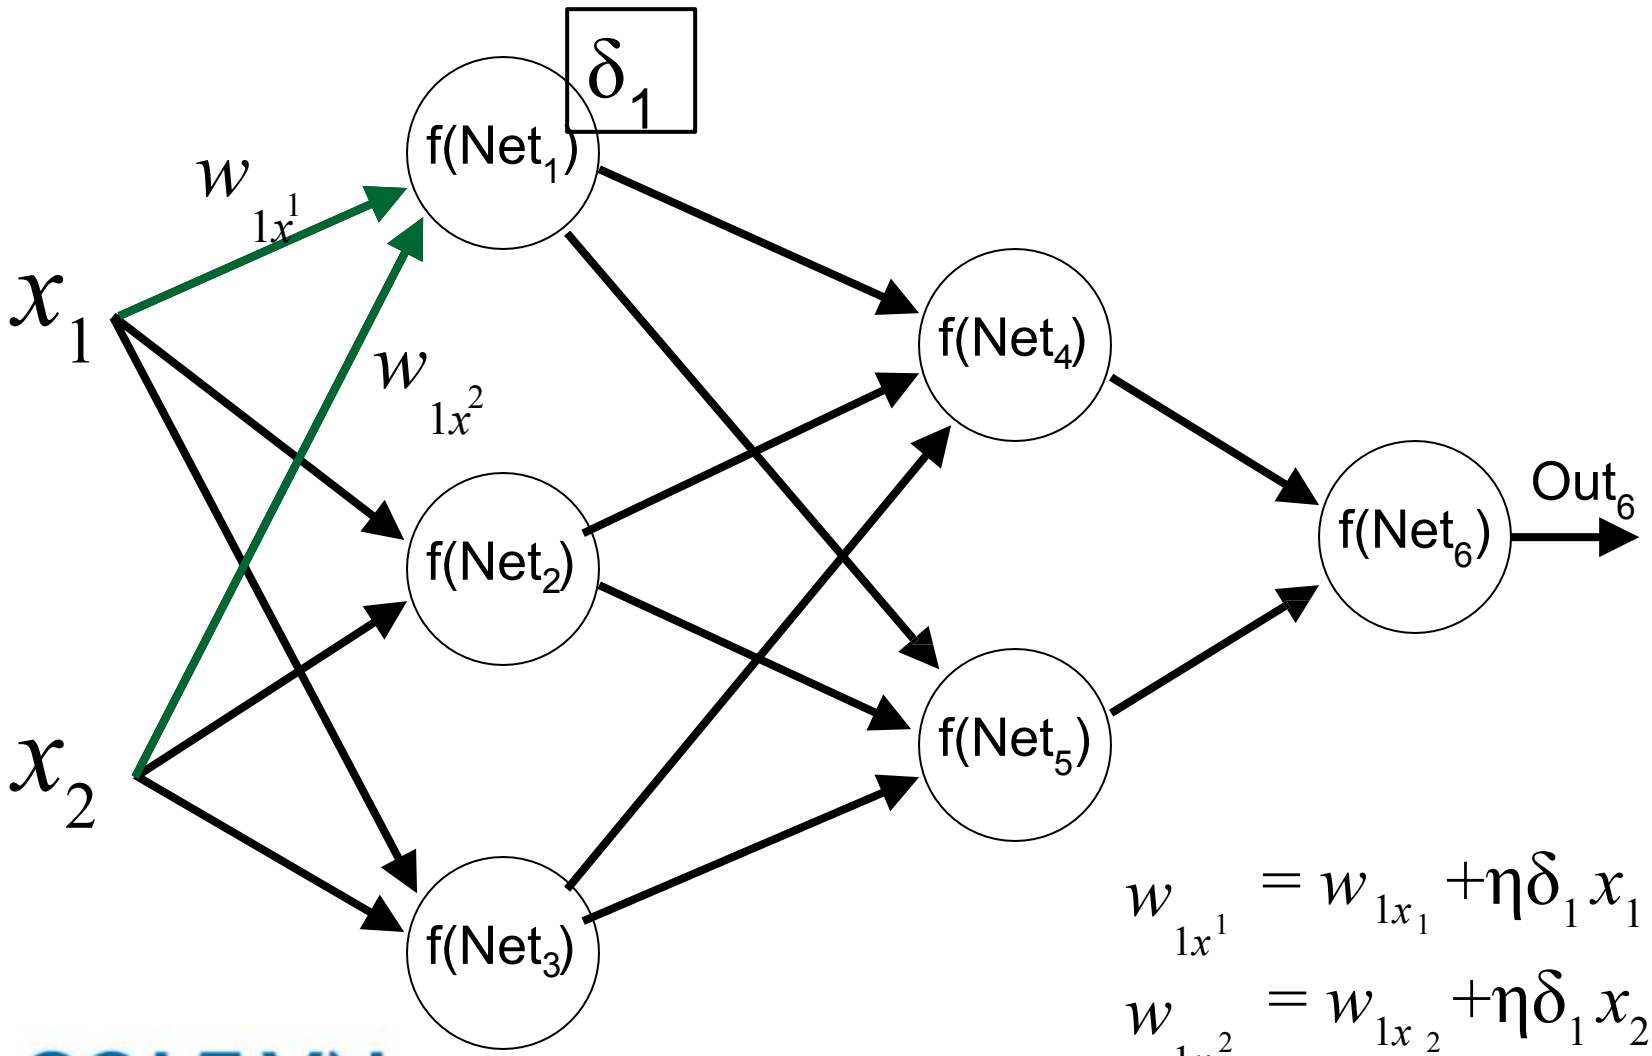

$$w_{1x_1} = w_{1x_1} + \eta\delta_1 x_1$$

$$w_{1x_2} = w_{1x_2} + \eta\delta_1 x_2$$

COLE.VN
Connecting knowledge

Giải thuật BP: Cập nhật trọng số (2)

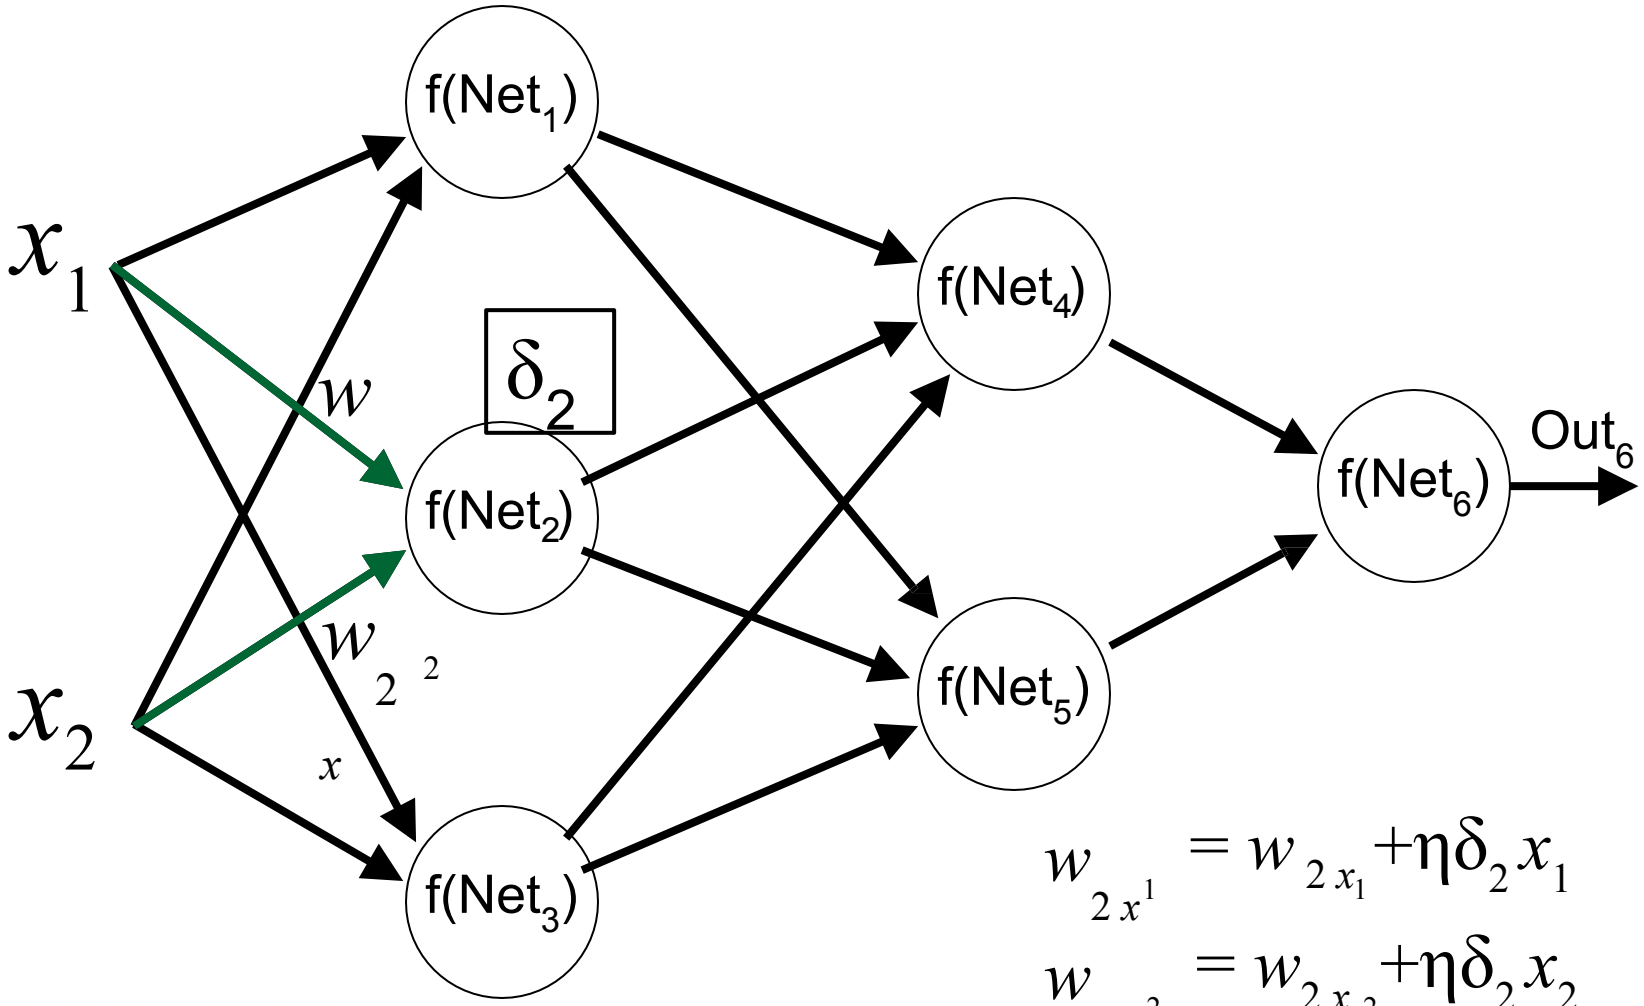

$$w_{2x^1} = w_{2x_1} + \eta\delta_2 x_1$$

$$w_{2x^2} = w_{2x_2} + \eta\delta_2 x_2$$

COLE.VN
Connecting knowledge

Giải thuật BP: Cập nhật trọng số (3)

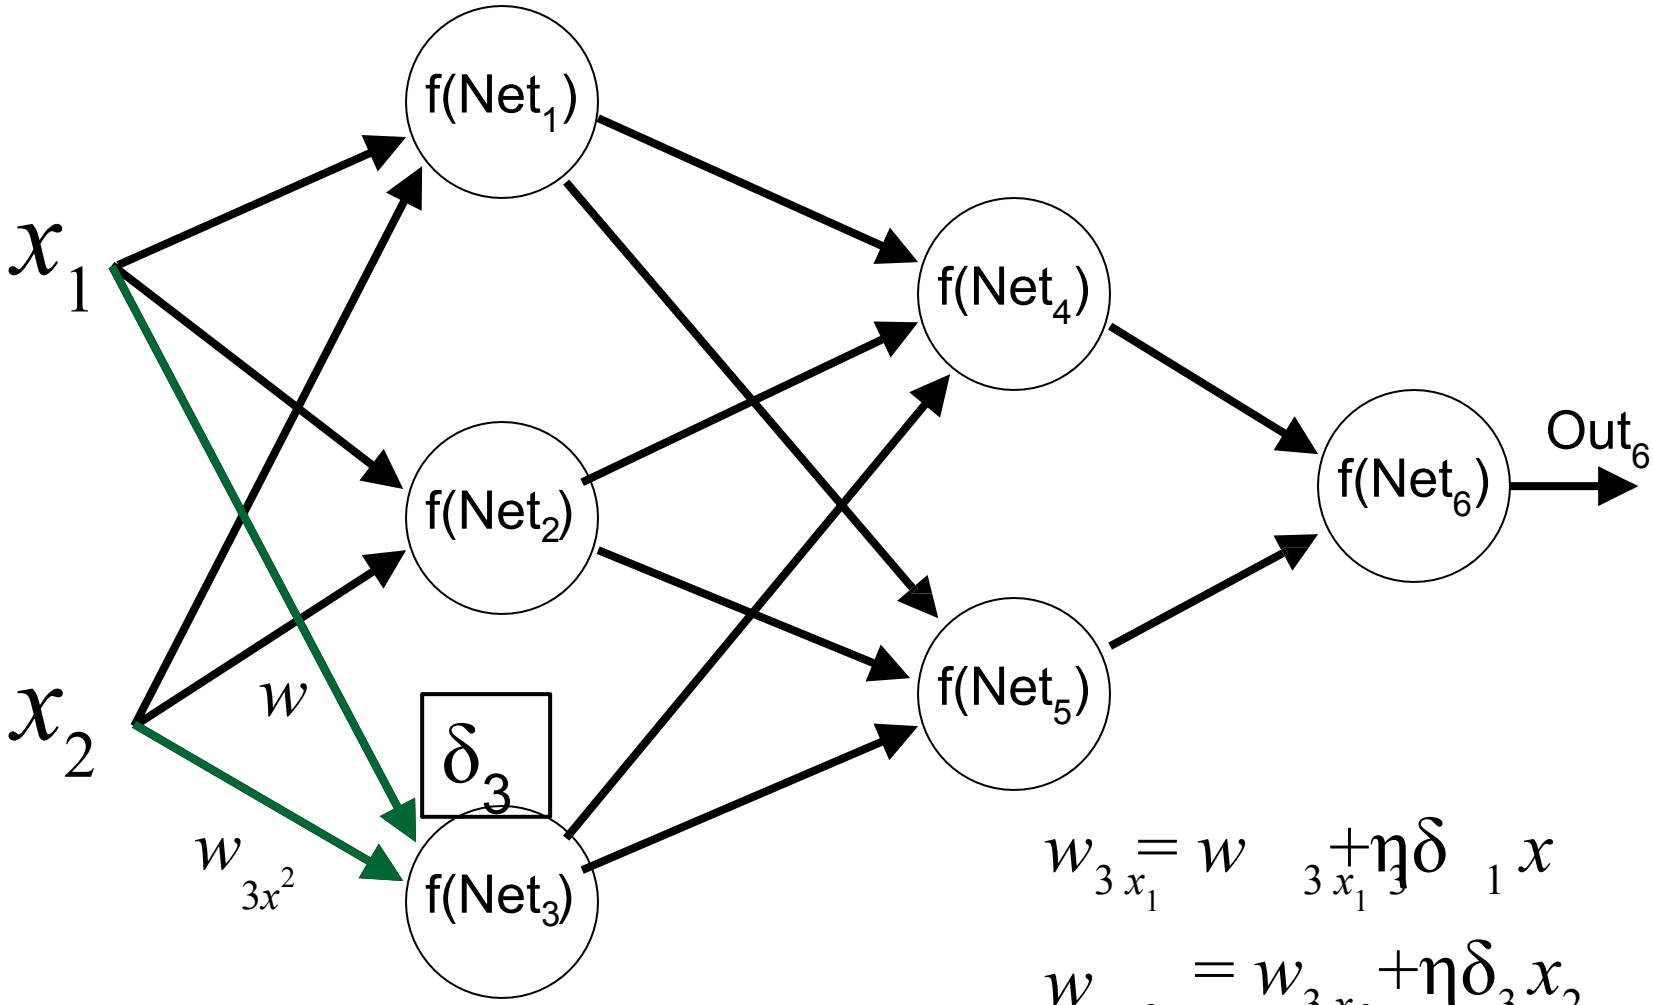

$$w_{3\,x_1} = w_{3\,x_1} + \eta\delta_3 x_1$$

$$w_{3\,x^2} = w_{3\,x_2} + \eta\delta_3 x_2$$

COLE.VN
Connecting knowledge

Giải thuật BP: Cập nhật trọng số (4)

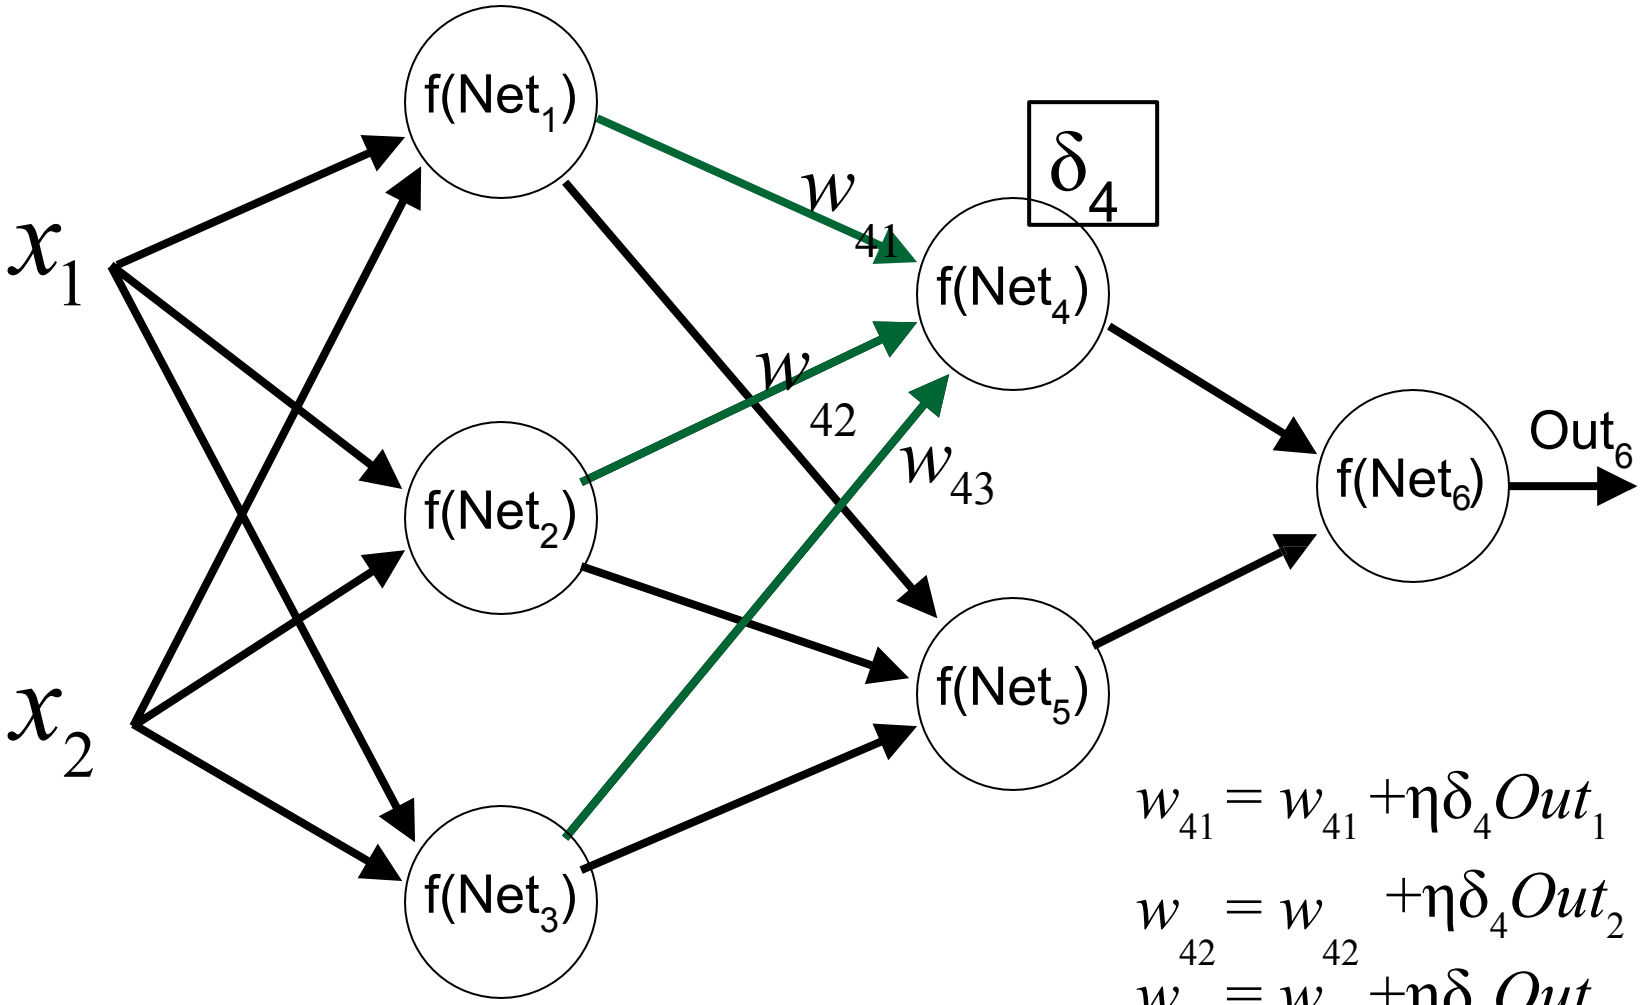

$$w_{41} = w_{41} + \eta\delta_4 Out_1$$
$$w_{42} = w_{42} + \eta\delta_4 Out_2$$
$$w_{43} = w_{43} + \eta\delta_4 Out_3$$

Giải thuật BP: Cập nhật trọng số (5)

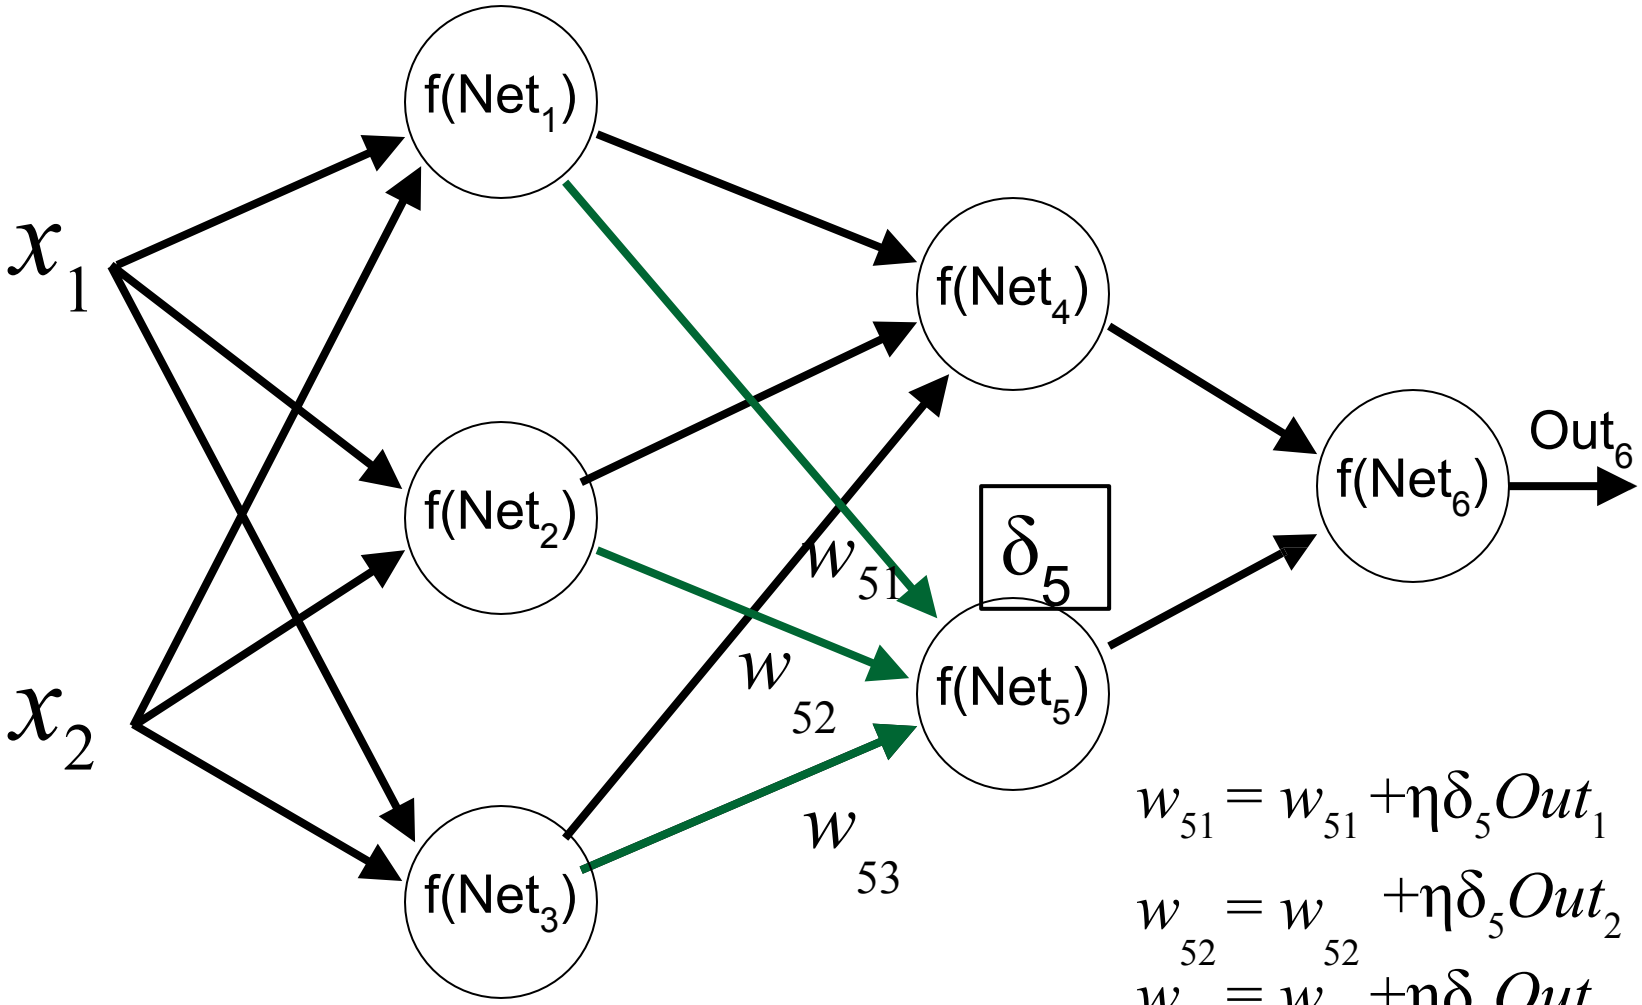

$$w_{51} = w_{51} + \eta \delta_5 Out_1$$

$$w_{52} = w_{52} + \eta \delta_5 Out_2$$

$$w_{53} = w_{53} + \eta \delta_5 Out_3$$

Giải thuật BP: Cập nhật trọng số (6)

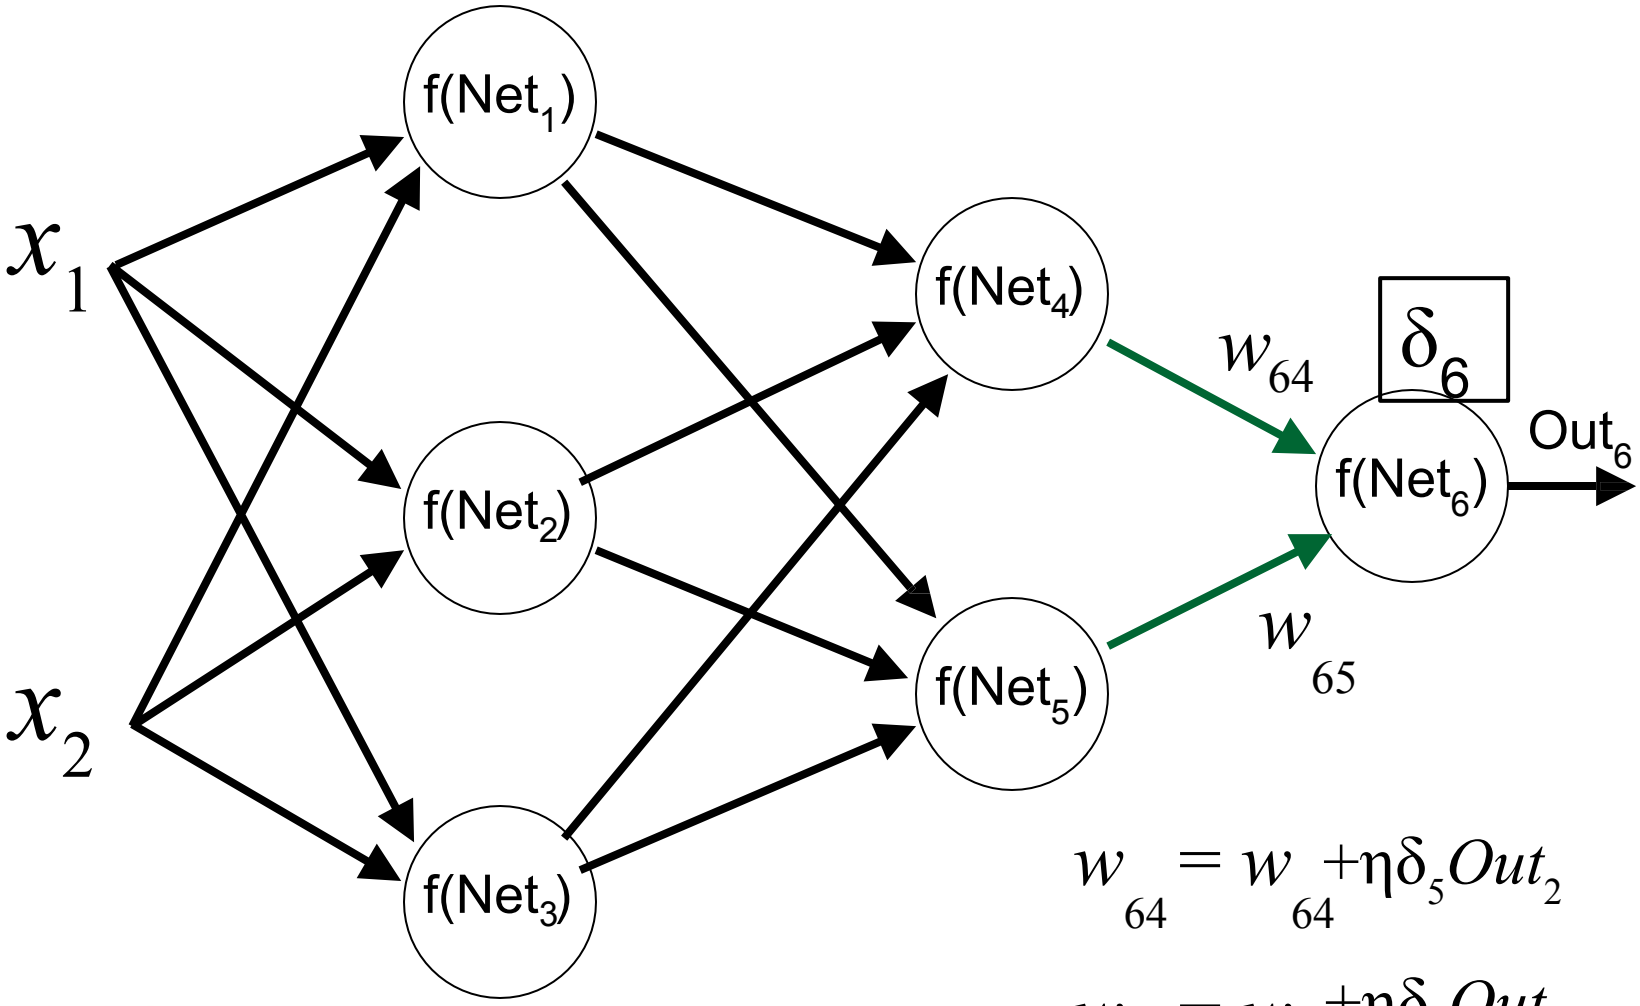

$$w_{64} = w_{64} + \eta \delta_5 Out_2$$

$$w_{65} = w_{65} + \eta \delta_5 Out_2$$

BP: Khởi tạo giá trị của các trọng số

- Thông thường, các trọng số được khởi tạo với các giá trị nhỏ ngẫu nhiên
- Nếu các trọng số có các giá trị ban đầu lớn
  - Các hàm sigmoid sẽ đạt trạng thái bão hòa sớm
  - Hệ thống sẽ tắc ở một điểm yên ngựa (saddle/stationary points)

BP: Tốc độ học (Learning rate)

- Ảnh hưởng quan trọng đến hiệu quả và khả năng hội tụ của giải thuật học BP
  - Một giá trị η lớn có thể đẩy nhanh sự hội tụ của quá trình học, nhưng có thể làm cho hệ thống bỏ qua điểm tối ưu toàn cục hoặc hội tụ vào điểm không tốt (saddle points)
  - Một giá trị η nhỏ có thể làm cho quá trình học kéo dài rất lâu
- Thường được chọn theo thực nghiệm (experimentally) đối với mỗi bài toán
- Các giá trị tốt của tốc độ học ở lúc bắt đầu (quá trình học) có thể không tốt ở một thời điểm sau đấy
  - Sử dụng một tốc độ học thích nghi (động)?

BP: Momentum

- Phương pháp *Gradient descent* có thể rất chậm nếu η nhỏ, và có thể dao động mạnh nếu η quá lớn
- Để giảm mức độ dao động, cần đưa vào một thành phần momentum

$$\Delta w^{(t)} = -\eta \nabla E^{(t)} + \alpha \Delta w^{(t-1)}$$

trong đó α ($\in[0,1]$) là một tham số momentum (thường lấy =0.9)

- Dựa trên các kinh nghiệm, ta nên chọn

các giá trị hợp lý cho tốc độ học và momentum thoả mãn

$$(\eta + \alpha) \gtrsim 1$$

trong đó $\alpha > \eta$ để tránh dao động

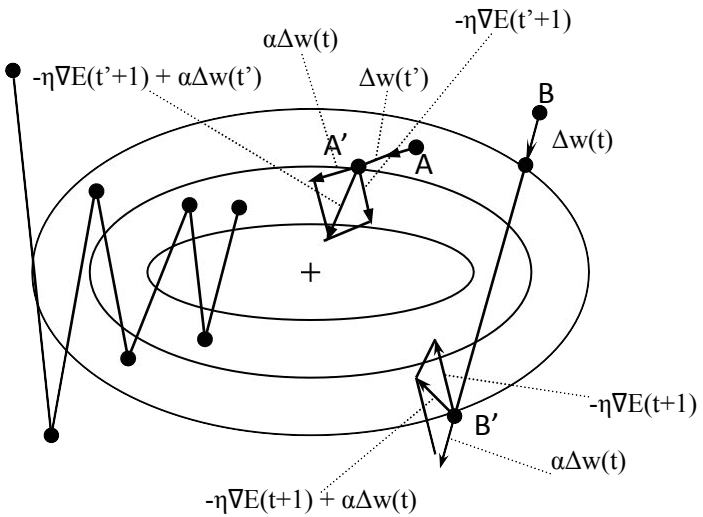

Gradient descent đối với một hàm lỗi bậc 2 đơn giản.

Quỹ đạo bên trái không sử dụng momentum.

Quỹ đạo bên phải có sử dụng momentum.

BP: Số lượng các nơ-ron ở tầng ẩn

- Kích thước (số nơ-ron) của tầng ẩn là một câu hỏi quan trọng đối với việc áp dụng các mạng nơ-ron lan truyền tiến nhiều tầng để giải quyết các bài toán thực tế
- Trong thực tế, rất khó để xác định chính xác số lượng các nơ-ron cần thiết để đạt được một độ chính xác mong muốn của hệ thống
- Kích thước của tầng ẩn thường được xác định qua thí nghiệm (experiment/trial and test)

ANN: Giới hạn học

- Các hàm nhị phân (Boolean functions)
  - Bất kỳ hàm nhị phân nào cũng có thể học được (xấp xỉ tốt) bởi một ANN sử dụng 1 tầng ẩn
- Các hàm liên tục (Continuous functions)
  - Bất kỳ một hàm liên tục bị giới hạn (bounded continuous function) nào cũng có thể học được (xấp xỉ) bởi một ANN sử dụng 1 tầng ẩn [Cybenko, 1989; Hornik et al., 1991]

ANN: Ưu điểm, Nhược điểm

- Các ưu điểm
  - Bản chất (về cấu trúc) hỗ trợ tính toán song song ở mức cao
  - Đạt độ chính xác cao trong nhiều bài toán (ảnh, video, âm thanh, văn bản)
  - Rất linh động trong kiến trúc mạng
- Các nhược điểm
  - Không có quy tắc tổng quát để xác định cấu trúc mạng và các tham số học tối ưu cho một (lớp) bài toán nhất định
  - Không có phương pháp tổng quát để đánh giá hoạt động bên trong của ANN (vì vậy, hệ thống ANN bị xem như một "hộp đen")
  - Rất khó (không thể) đưa ra giải thích cho người dùng
  - Lý thuyết nền tảng còn ít, để giúp giải thích được những thành công trong thực tế

ANN: Áp dụng khi nào?

- Dạng của hàm học không xác định được trước
- Không cần thiết (hoặc không quan trọng) phải đưa ra giải thích cho người dùng đối với các kết quả
- Chấp nhận thời gian (khá) lâu cho quá trình huấn luyện
- Có thể thu thập một lượng lớn các nhãn cho dữ liệu.
- Các miền liên quan đến: image, video, speech, text

Tổng kết buổi học

- Các thành phần cấu tạo thành mạng nơ ron nhân tạo
- Các thuật toán học cho mạng nơ ron nhân tạo

THANK YOU !

COLE.VN
Connecting knowledge

www.cole.vn